



硕士学位论文

低分辨率环境下的微表情识别

作者姓名: 李桂锋

指导教师: 彭进业 教授 西北大学

学位类别: 工学硕士

学科专业: 电子与通信工程

培养单位: 信息科学与技术学院

2019年6月

Micro-expression Recognition Under Low-resolution Case

**A thesis submitted to
Northwest University
in partial fulfillment of the requirements
for the degree of
Master of Engineering
in Electronics and Communication Engineering
By
Li Guifeng
Supervisor: Peng Jinye Professor**

June 2019

西北大学学位论文知识产权声明书

本人完全了解西北大学关于收集、保存、使用学位论文的规定。学校有权保留并向国家有关部门或机构送交论文的复印件和电子版。本人允许论文被查阅和借阅。本人授权西北大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。同时授权中国科学技术信息研究所等机构将本学位论文收录到《中国学位论文全文数据库》或其它相关数据库。

保密论文待解密后适用本声明。

学位论文作者签名：_____ 指导教师签名：_____

年 月 日 年 月 日

西北大学学位论文独创性声明

本人声明：所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，本论文不包含其他人已经发表或撰写过的研究成果，也不包含为获得西北大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：_____

年 月 日

摘要

人脸表情在我们的社交互动中发挥着重要作用，因为它传达了丰富的信息。我们可以从一张人脸图像中阅读很多内容，但是如果缺少特殊设备，我们也无法感知到这些信息。本文采用计算机视觉方法分析肉眼难以察觉的微妙的面部信息：微表情。

微表情是快速、不自主的面部表情，属于一种基本的非言语行为，它揭示了人们不打算表达的情感。人们很难感知微表情，因为它们太快和微弱，因此自动微表情分析是很有价值的工作，具有重大的应用前景。例如它在国家安全、计算机辅助诊断等领域有着广泛的应用，这促使我们对自动微表情识别进行研究。然而，从监视视频捕获的图像容易遭受低质量问题，这导致微表情识别算法在实际应用中产生困难。由于捕获图像的质量较低，现有算法无法达到预期的效果。为了解决这个问题，我们用人脸 Hallucination 方法对低分辨率环境下的微表情识别问题进行了全面的研究。本文综述了微表情研究的进展，并分四部分进行描述。(1) 我们介绍了目前存在的微表情数据集，着重介绍了第一个自发的微表情数据集——SMIC。数据的缺乏阻碍了微表情的分析研究。由于很难收集自发的微表情，所以引入用于诱导和注释 SMIC 的协议以帮助将来对微表情数据的收集。(2) 介绍了基于传统机器学习算法的低分辨率环境下的微表情识别框架，其在两个成熟的数据集——SMIC 和 CASME 上进行了实验，实验结果表明，所提出的框架在低分辨率情况下获得了良好的识别结果，这结束了现有算法无法识别低分辨率微表情的处境。(3) 采用数据增强和数据集融合的方法对现有数据集进行扩充，引入了时下最先进的针对图像序列的卷积神经网络——P3D ResNet 网络从深度特征层面识别低分辨率的微表情，该方法与基于传统机器学习的算法相比，准确度得到进一步提升。(4) 提出了一种低分辨率环境下微表情识别系统——LMERS，用于低分辨率环境下微表情的识别。

最后，我们总结了工作的贡献，并基于当前工作的局限性提出了关于微表情研究的未来计划。还计划将微表情和心率（可能还有来自面部的其他微妙信号）结合起来构建用于情感状态分析的多模式系统。

关键词：微表情识别，监控视频，低分辨率，超分辨率，Fast LBP-TOP

ABSTRACT

The face plays an important role in our social interactions as it conveys rich sources of information. We can read a lot from one face image, but there is also information we cannot perceive without special devices. The thesis concerns using computer vision methodologies to analyse subtle facial information that can hardly be perceived by naked eyes: the micro-expression.

Micro-expressions are rapid, involuntary facial expressions that belong to an essential non-verbal behavior which reveals emotions people do not intend to show. It is difficult for people to perceive Micro-expressions as they are too fast and subtle, thus automatic Micro-expressions analysis is a valuable work which may lead to important applications. For example, it has a wide range of applications in the national security and computer aided diagnosis, etc., which encourages us to conduct the research of automatic micro-expression recognition. However, the images captured from surveillance video easily suffer from the low-quality problem, which causes the difficulty in real applications. Due to the low quality of captured images, the existing algorithms are not able to perform as well as expected. For addressing this problem, we conduct a comprehensive study about the micro-expression recognition problem under low-resolution cases with face hallucination method. In the thesis, the progresses of Micro-expressions studies are reviewed, and four parts of work are described. (1) We introduced the existing Micro-expressions database, focusing on the first spontaneous Micro-expressions database, the SMIC. The lacking of data is hindering Micro-expressions analysis research. Since it is difficult to collect spontaneous Micro-expressions, the protocol for inducing and annotating SMIC is introduced to help future Micro-expressions collections. (2) Introduced the Micro-expressions recognition framework based on traditional machine learning algorithm under low-resolution cases. Experiments were carried out on two mature databases, the SMIC and the CASME. The experimental results show that the proposed framework obtains promising results under low-resolution cases, which ends the situation where the existing algorithm cannot recognize the low-resolution Micro-expressions. (3) Extend the existing databases by data augmentation and dataset fusion, and introduce the most advanced convolutional neural network, the P3D ResNet, for image sequences to identify low-resolution Micro-expressions from the deep feature level. Compared with the algorithm based the traditional machine learning, the accuracy of this

method is further improved. (4) A Micro-expression recognition system under low-resolution cases (LMERS) was proposed for the recognition of Micro-expressions under low-resolution cases.

At last, we summarize the contributions of the work, and propose future plans about Micro-expressions studies based on limitations of the current work. It is also planned to combine the Micro-expressions and heart rate (maybe also other subtle signals from face) to build a multimodal system for affective status analysis.

Keywords: Micro-expression recognition, Surveillance video, Low-resolution, Super-resolution, Fast LBP-TOP

插图索引

图 1	人脸宏表情样本示例（CK+ 数据集）	12
图 2	一个消极的微表情片段示例（SMIC 数据集）	14
图 3	微表情数据采集示意图	15
图 4	人脸面部表情肌肉划分	17
图 5	LBP 特征的光照鲁棒性	18
图 6	LBP-TOP 特征提取过程	19
图 7	光流大小和方向的表现	20
图 8	三维卷积神经网络架构	23
图 9	ResNet 的残差学习模块	24
图 10	低分辨率环境下微表情识别框架	27
图 11	来自 SMIC-HS 数据集的两帧	28
图 12	ASM 算法标定的 68 个人脸关键点	30
图 13	LWM 算法人脸对齐后的图像	30
图 14	TIM 方法映射过程	31
图 15	超分辨重建过程	33
图 16	LBP-TOP 特征提取过程	36
图 17	低分辨率图像	38
图 18	不同分辨率图像重建结果比较	39
图 19	不同数据集不同分辨率的图像序列的识别准确度	40
图 20	不同分辨率图像序列的识别准确度混淆矩阵	41
图 21	基于深度学习方法的低分辨率环境下微表情识别网络框架	44
图 22	三种 P3D 块设计	49
图 23	三种 P3D 瓶颈块结构设计	49
图 24	P3D-A、P3D-B、P3D-C 级联的 P3D 残差网络	49
图 25	直方图均衡化样例	50
图 26	微表情识别系统功能结构图	52
图 27	低分辨率环境下微表情识别系统	53
图 28	低分辨率环境下微表情识别样例	53

表格索引

表 1	微表情的研究方法	8
表 2	摆拍微表情数据集	13
表 3	自发微表情数据集	17
表 4	实验中使用的数据集	38
表 5	重建图像序列的平均 PSNR (dB) 指标	39
表 6	重建图像序列的平均 SSIM 指标	39
表 7	不同分辨率图像在不同数据集上的识别精度比较	42
表 8	融合后数据集情况	44

符号对照表

符号	符号名称
\otimes	哈达玛积
λ	惩罚系数
$\phi(\cdot)$	从原始空间到无限维再生核希尔伯特空间的映射
ω	结合系数
η	基于像素的正则项系数
α	基于块的正则项系数
σ	均方误差系数

缩略语对照表

缩略语	英文全称	中文对照
ME	Micro Expression	微表情
TIM	Temporal Interpolation Model	时间插值模型
BART	Brief Affect Recognition Test	微表情识别标准测验
AU	Action Unit	动作单元
METT	Micro Expression Training Tool	微表情训练工具
FD	Feature Difference	特征差异
PD	Peak Detection	峰值检测
LOSO	Leave One Subject Out	留一法
FACS	Facial Action Coding System	面部动作编码系统
EMFACS	Emotion Facial Action Coding System	面部表情动作编码系统
NIR	Near Infrared Videos	近红外视频
HS	High Speed Video	高速视频
JACBART	Japanese and Caucasian Brief Recognition Test	日本人与高加索人短暂
VIS	Normal Color Video	普通彩色视频
SVM	Support Vector Machine	支持向量机
MKL	Multiple Kernel Learning	多核学习
LBP-TOP	Local Binary Patterns on Three Orthogonal Planes	三正交平面局部二值模型
RF	Random Forest	随机森林
STCLQ	SpatioTemporal Completed Local Quantization Patterns	时空局部量化模型
TICS	Tensor Independent Color Space	张量独立颜色空间
PCA	Principal Component Analysis	主成分分析
LBP-SIP	LBP-Six Intersection Points	六交叉点局部二值模型
STM	Selective Transfer Machine	选择转移机
CNN	Convolutional Neural Networks	卷积神经网络
ASM	Active Shape Model	主动形状模型
JAFFE	The Japanese Female Facial Expression	日本女性表情库

AAM	Active Appearance Models	主动外观模型
PSNR	Peak Signal to Noise Ratio	峰值信噪比
SSIM	Structural Similarity Index	结构相似性
LWM	Local Weighted Mean	局部加权平均
LSVM	Linear Support Vector Machine	线性支持向量机
RKHS	Reproducing Kernel Hilbert Space	再生核希尔伯特空间
MSE	Mean Square Error	均方误差
GPU	Graphics Processing Unit	图形处理器
CNN	Convolutional Neural Networks	卷积神经网络
LSTM	Long Short-Term Memory	长短期记忆网络
TLCNN	Transfer Long-term Convolutional Neural Network	转移长期卷积神经网络
P3D ResNet	Pseudo-3D Residual Network	伪三维残差网络

目 录

摘 要	I
ABSTRACT	III
插图索引	V
表格索引	VII
符号对照表	IX
缩略语对照表	XI
第一章 绪论	1
1.1 研究背景与意义	1
1.1.1 微表情研究的意义	1
1.1.2 计算机视觉对微表情研究的意义	2
1.2 国内外研究现状	4
1.2.1 人工微表情识别训练工具研究	4
1.2.2 自动微表情识别研究	4
1.3 本文的研究内容	8
第二章 相关工作	11
2.1 宏表情和微表情	11
2.1.1 宏表情数据集	11
2.1.2 早期微表情数据集	12
2.1.3 自发微表情数据集	13
2.1.4 宏表情与微表情比较	17
2.2 微表情特征提取的一般方法	18
2.2.1 基于纹理信息的 LBP-TOP 特征提取符	18
2.2.2 基于光流法的特征提取	19
2.2.3 基于 Gabor 的特征提取	21
2.3 相关深度学习网络	22
2.3.1 三维卷积神经网络	22
2.3.2 残差神经网络	24

第三章 基于传统机器学习方法的低分辨率环境下微表情识别	27
3.1 低分辨率微表情数据获取	28
3.2 数据预处理	29
3.2.1 主动形状模型	29
3.2.2 局部加权平均算法	29
3.2.3 时间插值模型	30
3.3 超分辨重建过程	32
3.3.1 基于块的方法	33
3.3.2 基于像素的方法	34
3.4 微表情的特征提取与分类	35
3.4.1 LBP-TOP 特征提取	35
3.4.2 线性支持向量机及交叉验证	35
3.5 实验设置及分析	36
3.6 本章小结	42
第四章 基于深度学习方法的低分辨率环境下微表情识别	43
4.1 数据集预处理	44
4.1.1 数据集融合	44
4.1.2 数据增强	45
4.2 特征提取及识别	46
4.2.1 伪 3D 块	46
4.2.2 P3D ResNet	48
4.3 实验设置及分析	49
4.3.1 数据增强	49
4.3.2 特征提取及识别	49
4.4 本章小结	50
第五章 低分辨率环境下微表情识别系统	51
5.1 需求分析	51
5.2 系统设计	51
5.2.1 功能设计	51
5.2.2 界面设计	52
5.2.3 操作样例	52
5.3 本章小结	54
第六章 总结与展望	55
6.1 总结	55
6.2 存在的问题与展望	56
6.2.1 存在的问题	56
6.2.2 展望	56

参考文献	57
致谢	63
攻读硕士学位期间取得的科研成果	65

第一章 绪论

微表情（Micro Expressions），心理学名词，心理应激微反应的一部分，是人类表达自身情感信息的重要非语言性行为。微表情从人类本能出发，在大多数情况下，不受思想的控制，无法掩饰，也不能伪装^[1]。因为它无法伪装的特性起初被人们用来作为鉴谎的辅助工具，随着人们对其不断深入的研究发现它在临床诊断、司法系统等有着很高的应用价值。近几年来随着计算机技术的不断发展，人们利用计算机视觉对微表情识别研究有了突飞猛进的成果，但就目前而言，还没有团队在低分辨率环境下对微表情做任何研究。本文从实际应用的角度出发，分析实际场景中面临的各种低质量问题，分别使用传统机器学习方法和深度学习方法对微表情识别。

本章主要阐述微表情识别研究的意义和低分辨率环境下微表情识别的重要性，国内外对微表情识别相关的研究和发展趋势，最后概述了文章的内容和结构分配。

1.1 研究背景与意义

达尔文在 1872 年出版了《The Expression of Emotions in Man and Animals》，从此拉开了人类对面部表情的系统性研究。时至今日，人类对面部表情的研究已经非常丰富与成熟，但主要关注的是显而易见的宏观表情（Macro Expressions），虽然在 1966 年 Haggard 和 Isaacs 首次提出了微表情现象（Micro-momentary Facial Expressions），但当时并未引起人们的普遍重视。直到三年后（1969 年），Ekman 和 Friesen 在临床发现了微表情，这一发现奠定了微表情在临床辅助治疗上的重要地位^[2]，也开启了微表情的研究热潮。

本节将从微表情研究的意义和计算机视觉对微表情研究的意义两方面分析。

1.1.1 微表情研究的意义

加利福尼亚大学洛杉矶分校的心理学教授 Albert Mehrabian 在上世纪六十年代发现了人际交流中的“55384”原则，他提出有效的沟通技巧应该包含三大要素：身体语言、声音和谈话内容^[3]。其中谈话内容传递的信息量是总信息量的 7%，声音（包括交谈时的语气、音调和音量）传递的信息量占总信息量的 38%，剩下的 55% 来自身体语言（包括谈话期间身体姿势、肢体动作、面部表情、眼神和目光等），也就是说身体语言比谈话内容能传达更多有价值的信息。论文中阐明，出现这种情况的主要原因是谈话内容（口头语言）可以有意识地被控制，而身体语言这种非语言行为是无意识的举动，人类的主观意识很难控制动作语言行为。身体语言由三部分构成：表情语言、动作语言和空间语

言。表情语言指的是通过面部肌肉运动和眼睛神态所传递出来的思想感情，动作语言指人类通过身体各个部位的动作或姿态来传递感情，空间语言主要指由个体与个体之间所保持的间距所形成的一种信息表达方式。在这三种身体语言中最容易被观察到的就是表情语言，艾伯特教授的这项发现说明了表情语言的重要性。

神经学家 Paul Donald MacLean 于上世纪五十年代提出了“大脑三位一体”理论 (The Triune Brain)，他认为人类颅腔内的脑并非只有一个，而是三个，这三个脑作为人类不同进化阶段的产物，按照出现顺序依次覆盖在已有的脑层之上，如同考古遗址一样^[4]。根据在进化史上出现的先后顺序，他将人脑分成“爬行动物脑” (Reptilian brain)、“古哺乳动物脑” (Paleomammalian Brain) 和“新哺乳动物脑” (Neomammalian Brain) 三大部分，它们分别对应人脑的脑干 (Archipallium)、边缘系统 (Limbic System) 和新皮质 (Neocortex)，它们共同控制着人类的身体行为。新皮质被称作“爱说谎的大脑”，经常会因为当事人的某种需要而出现说谎的现象。语言等由新皮质大脑控制的行为是不可信的，欺骗的嫌疑很大，想要得知对方内心的真实感受，必须观察对方边缘系统所控制的表情或肢体动作。边缘系统是控制人类情感的中心，管理着人类的非语言行为表达，因此是分析身体语言的重点。让人不加思索的产生本能反应是它的一大特点，它反映出了一个人最真实的一面，这很难被控制和掩饰。比如，当听到刺耳的噪音时你会不自主地捂住耳朵、手碰到高温或极寒物体时会马上缩回等。所以边缘系统的行为是诚实可信的行为，是人类的思想、感觉和意图的真实反应，也是人类生存、本能的反应，它属于微反应中除微语言以外的非语言行为反应，它包括了微动作 (Micro Action)、微表情。

从上述例子可以看出，有关微表情的研究在心理学和神经学两大学科都有着充分的理论依据。Ekman 等人在临幊上发现微表情是来自于观看一位有自杀倾向的精神病患者的视频，视频中患者在回答医生问题时表现的很开心，没有任何想要自杀的异常迹象，但在随后的二次会谈中患者向医生承认其状况并未好转，而且她曾隐藏了自杀的计划。Ekman 和 Friesen 在逐帧慢放视频时发现确实存在两帧和绝望有关的负面表情，这与患者的二次会谈内容相吻合，但只持续了 1/12 s。之后的几十年里 Ekman 和他的同事继续研究微表情，在不断的实践中量化并定义了微表情，这也引起了越来越多学术界和商业界人士的兴趣，目前微表情已经被应用到了众多领域，比如国家安全、司法系统、政治选举、临床诊断、公共管理和教育领域等^[5]。

1.1.2 计算机视觉对微表情研究的意义

我们人类是优秀的“人脸识别专家”，我们已经习惯甚至并没有意识到这一点。与其他类型的物种相比，我们人类为应对复杂的社交交互问题，大脑已经开发了特殊的识别脸部信息的功能模块，以便我们更好地从人脸中获取更丰富的信息，所谓“察言观

色”就是很好的佐证。当然，人脸也是丰富的视觉信息的来源之处，我们可以从人脸中读取很多信息。比如眼前之人如果是著名人士，我们可以立即认出他或她，如果是陌生人，我们可以对这个人的性别、年龄、种族等做出基本正确的猜测，同时如果该人脸存在表情，我们也可以大致感知他或她的情绪状态。然而尽管我们是人脸识别专家，但这并不意味着我们已经解析出了全部的人脸信息，因为仍然存在部分无法用肉眼读取的深层次信息。

与其他感官（例如听觉和嗅觉）相比，我们的视觉认知功能在我们的大脑中更加精巧地被构建。然而，我们获取视觉信息的能力仍然受到生理机制的限制。超出我们感知范围的视觉变化（在空间域中太微妙或在时域中太快）将被我们的眼睛忽略。比如我们很难从人脸上观察到某个微表情，因为微表情会短暂且快速地发生，所涉及的肌肉运动强度也非常微弱，甚至表情发出者和观察者都察觉不到，尤其在高风险条件下微表情出现的机率更高，被察觉的可能性也更低。研究人员经过严密的统计，发现微表情持续时间最长为 1/2 秒而最短只有 1/25 秒，所涉及的肌肉运动强度更是微乎其微，而正常的表情（宏观表情）一般持续时间在 1/2 秒到 5 秒之间，有一个起承转合的过程。^[6-8]

由于微表情识别务实的使用价值，其提出者 Ekman 从 2005 年开始对英国情报机构、美国中央情报局等各国机构进行微表情识别培训，而那时他已经 71 岁高龄了^[9]。他教辩护律师、健康专家、扑克选手，甚至对配偶心怀猜疑的人识破谎言，并且制作了网络课程。但他坦言人类对于微表情的识别能力终归是有限的，不仅要花费大量的人力和物力培训微表情识别专家，而且准确度不高，同时还伴有影响正常生活的风险^[10]。Ekman 曾说自己的识谎能力影响到了日常生活，他从不试图去识破周围朋友、亲戚的微表情，“去揭露每个人的微表情，揭穿每个人的谎言，这只会让自己的生活痛苦万分”。

同时当前对微表情研究的研究中，需要使用 FACS (Facial Action Coding System) 对包含被试微表情的视频进行逐帧的编码^[11]。但是，不仅 FACS 编码的训练比较费时，编码者一般都需要接受 100 小时的训练才能达到初步熟练的程度；而且使用 FACS 进行编码也很费时，编码 1 分钟的视频平均需要 2 个小时^[12]。为了更快地对基本表情编码，在 FACS 基础上，研究者发展出了一套附加的编码系统 EMFACS (Emotion Facial Action Coding System)，但人工对视频进行逐帧编码依然费时费力，这极大地限制了目前的微表情研究。因此，有效的微表情自动分析工具是开展微表情表达研究需要解决的一个重要问题。

计算机的发明是为了帮助人类更好地处理人类不想去处理的任务，而识别人脸微表情这种会影响到日常生活的任务就是计算机存在的价值所在。而且当通过摄像机和计算机系统对待分析者分析时，不仅采集到的表情真实可靠（采集中采集对象并不知情，不

存在任何干扰)而且通过计算机算法可以发现细微的人类无法察觉的表情变化，并且已经有大量的实验证明计算机的识别能力确实高于人类^[13]。我们可以更好更快的训练计算机完成人类能够完成的任务，如人脸检测、人脸识别，同时我们还可以训练计算机执行我们无法完成的任务，如捕获肉眼难以察觉的细微信息^[14]。

1.2 国内外研究现状

1.2.1 人工微表情识别训练工具研究

早期研究中，研究人员注重于测量或训练个体的微表情识别能力。Ekman 和 Friesen 在 1974 年制定了第一个微表情识别标准测验机制——BART (Brief Affect Recognition Test)，但当时的微表情识别标准测验有着很大的缺陷，它所呈现的微表情是孤立的呈现，这与现实生活中微表情的动态呈现方式完全不相符，这样的测验没有任何生态效度^[15,16]。1978 年，Ekman 发布了面部动作编码系统 FACS，他们将人脸部的肌肉划分为 43 块，将它们随机组合获得了 1 万多种表情，但其中只有 3000 种具有情感意义，Ekman 等人又根据人脸解剖学特点，将这 43 块肌肉划分成相互独立又相互联系的运动单元 (Action Unit, AU)，分析这些运动单元的运动特征和其所控制的主要区域，将这些信息与相关的表情匹配就能得出面部表情的标准运动。为了克服 BART 的缺陷，Matsumoto 等人在 2000 年开发了更完善的微表情识别测量工具 (Japanese and Caucasian Brief Affect Recognition Test, JACBART)，该测验具有很好的可信度和严密的实验过程^[17]。Ekman 等人在 2002 年根据日本人与高加索人短暂表情识别测验开发出了一个新的微表情识别训练工具 METT (Micro Expression Training Tool)，该训练工具有 7 种基本情绪的微表情，包括悲伤、恐惧、愤怒、厌恶、轻蔑、惊讶和高兴，METT 被应用在多种人群和领域，且对微表情受训者的识别能力有明显的提升^[18]。

1.2.2 自动微表情识别研究

除上述通过训练提升人工识别能力外自动地微表情识别系统也在如火如荼的发展中，研究者们已经开发出很多相关的算法，甚至在某些数据集的准确度可达 90% 以上，但这些数据集有个明显的缺点，所有的微表情均为摆拍 (Posed)，这一缺点有其产生的必然性，但也严重违背了微表情的定义。为了解决这一问题，国内外的研究团队相继发表了自发微表情数据集，如中科院心理所分别在 2013 年和 2014 年发布了 CASME^[19] 和 CAMSE II^[20] 两个版本的数据集，后者比前者有着更高的时空分辨率和更多的数据量，但参与者全部为蒙古利亚人种 (中国人)，在数据的多样性上有一定的不足；芬兰奥卢大学的 CMVS 团队在 2013 年发布了 SMIC 数据集^[21]，包括 8 名高加索人种和 8 名蒙古利亚人种，同时数据集中包含了高速视频数据 (High speed video, HS)、近红外视频数据

(Near infrared videos, NIR) 和普通彩色视频数据 (Normal color video, VIS); 英国曼彻斯特城市大学在 2017 年发布了 SAMM 数据集^[22], 是目前发表最新的数据集, 包括了几乎全部的人种 (蒙古利亚人种、高加索人种、尼格罗人种和大洋洲人种) 和均衡的性别比, 但其数据集只包含了高速灰度视频数据 (见表 1)。优秀的数据集提供了良好的实验基础, 自动微表情识别系统的研究主要集中在微表情检测 (Micro-expression Spotting) 和微表情识别 (Micro-expression Recognition)。

微表情的检测指在一个图像序列 (视频帧) 中检测微表情发生的起始时间点。有许多研究致力于类似的任务, 如检测普通的人脸表情、眨眼和人脸 AU^[23–25], 以及各种有效的算法被提出, 与微表情识别研究相比, 微表情检测的研究较少。由于缺乏自发的微表达数据, 大多数早期的微表达检测研究多采用摆拍的微表情数据。Shreve 等首次先提出了一种基于应变的光流方法来识别视频中的宏表情 (普通人脸表情, 微表情的反义词) 和微表情, 在 USF-HD 数据集 (摆拍的数据集) 中进行了测试, 同时他们还对从在线视频中收集的 28 个微表情进行了测试, 但是这个数据集很小, 没有发表^[26,27]。在另一组研究中, Polikovsky 等人提出了一种新的微表情检测方法, 他们使用三维梯度直方图作为特征描述符, 对中性面部微表情帧进行不同阶段 (起始、顶峰和终止) 分类^[28,29]。在他们的研究中, 将微表情检测任务作为分类任务, 并训练模型根据所涉及动作的阶段将视频片段分为四类。关于 Polikovsky 的研究, 有一点很好, 那就是作者试图在一个精细的层面上构建微表情的时间范围。这可能适用于摆拍的微表情片段, 因为它们具有相似的时间结构, 但不适用于自发的微表情, 因为在真实场景中, 微表情在其时间范围内存在显著差异。分类任务需要对视频预分割, 这在实际应用中也是一个问题。Wu 等人提出利用 Gabor 滤波器构建微表情识别系统进行微表情检测^[30]。该方法在 METT 训练数据上进行了测试, 取得了良好的效果。但有一点需要说明的是, METT 训练样本完全是合成的视频片段 (在一系列相同的中性人脸图像中间插入一张有情感的人脸图像)。在这些视频片段中, 表情的“开始”和“结束”非常的尖锐和突然, 上下文界线也非常清晰, 所以它们根本不能代表计算机真正的微表情检测问题。

虽然上述研究可能会为微表情检测提供潜在的贡献, 但一个主要的缺点是, 它们仅在摆拍的 (或 METT 等合成的) 微表达数据集上进行了测试。与自发微表情相比, 提出的数据更容易完成微表情的检测任务。摆拍或合成的微表情数据通常具有相似的时间范围结构, 即人为控制的起止时间点, 这与自发微表情之间存在显著差异。考虑到视频的上下文, 摆拍的微表情片段通常在视频中会禁止无关的动作, 所以摆拍的微表情片段通常具有更清晰的上下文。自发微表情视频的情况更加复杂, 由于普通人脸表情 (包含相同或相反的情绪价^[31])、眨眼和其他头部动作也可能发生, 并且还可能与自然情绪相互

重叠。这些在自发微表达数据中遇到的挑战，在以往的研究中利用摆拍的微表情数据都无法解决，因此利用自发微表情数据进行微表情检测还需要更多的工作。

论文 [32] 和其他几项研究使用了一种更简单的方法，即微表达“探测”来解决这个问题^[33–35]。在这些研究中，微表情检测被视为二分类问题，一组带标签的微表达片段与另一组非微表达片段进行分类。这些研究都是在自发微表情数据集中测试的，这是一个很大的优点。但是对于分类任务，训练和测试视频都需要进行适当的分割，这在实际应用中可能会遇到困难。二分类方法与直接从长视频中提取自发微表情的实际应用目标仍有较大差异。Li 等人提出了一种将特征差异（Feature Difference, FD）比较和峰值检测（Peak Detection, PD）相结合的微表情识别框架，这种方法是第一个用于真实微表情数据集检测微表情且行之有效的方法^[32]。在最近的另一篇文章中作者提出了一种基于概率框架的随机游走模型（Random walk model）来检测微表情，通过几何变形建模从视频片段中识别自发微表情片段，该方法被证明对 SMIC 和 CASMEII 都是有效的^[36]。

微表情识别的任务类似于普通人脸表情识别，差异处在于微表情片段（包含微弱面部运动的起始到终止的帧序列）的标签，具体是指根据表达的情感内容训练一个分类器将其分类为两个或两个以上的类别（例如快乐、悲伤等）。在众多已发表的文献中微表情识别的研究比微表情检测的研究更为突出，在摆拍和自发的数据集上提出并测试了很多算法。早期的工作都是从摆拍的微表情数据开始的。Polikovsky 和 Kameda 等人采用三维梯度描述符对 AU 标记的微表情进行识别，将提出的方法在自己采集的摆拍微表情数据上进行了测试^[29]。Wu 等人将 Gentleboost 和支持向量机（Support Vector Machine, SVM）分类器结合，在 METT 训练工具中识别合成的微表达样本。随着自发微表达数据库的出现，利用自发微表达数据库进行微表达识别的研究也越来越多。2011 年，论文 [32] 提出了第一个微表情识别方法，并在第一版的 SMIC 数据集上取得了很好的效果（第一版的 SMIC 数据集包含 77 个自发的微表情样本）。该方法采用时间插值模型（Temporal Interpolation Model, TIM）对微表情计算帧数，将其与和多核学习（Multiple Kernel Learning, MKL）结合捕获图像序列的主要变化，使用三正交平面的局部二值模型（Local Binary Patterns on Three Orthogonal Planes, LBP-TOP）特征作为描述符提取动态纹理作为微表情识别的特征，再用随机森林（Random forest, RF）作为分类器分类。这是首次尝试构建一个可行的方法来识别这些细微的面部行为，并在 77 个微表情样本上取得了很好的效果（二分类准确度为 71.4%）。同样的方法在新版本的 SMIC 数据集上进行了测试，在包含 164 个微表情的 SMIC-HS 数据集上得到了 48.78%（三分类）的识别结果。此后，论文 [32] 的研究结果被许多其他研究人员引用为微表情识别研究的基准。Ruiz-Hernandez 和 Pietikäinen 等人利用二阶高斯流的再参数化来生成更鲁棒的直

方图，在第一版 SMIC 数据库上得到了比论文 [32] 更好的识别结果^[33]。Huang 等人通过在时空域中的积分投影获得被试者（目标）的形状属性，将形状属性与时空域上的纹理信息结合组成新的特征，提出了时空局部量化模式 (SpatioTemporal Completed Local Quantization Patterns, STCLQP) 作为微表情识别的特征，在 SMIC 上实现了 64.02% 的精度^[37]。

几个其他的微表情识别研究使用了 CASMEII 微表情数据库。Wang 等人从张量独立颜色空间 (非普通的 RGB 颜色空间, Tensor independent color space, TICS) 中提取 LBP-TOP 进行微表情识别，并在 CASMEII 数据集进行测试^[38]。Wang 等人在其另一篇论文中，将局部时空方向特征与鲁棒主成分分析 (Principal Component Analysis, PCA) 的稀疏部分相结合一起用于微表情识别，在 CASMEII 上实现了 65.4% 的准确率^[39]。Wang 等人提出利用 6 个交叉点的局部二值模式 (LBP-Six Intersection Points, LBP-SIP) 进行微表情识别，并在 CASMEII 和 SMIC 上进行了测试，该方法是减少了 LBP-TOP 中的冗余信息^[40]。Huang 等人为了提高微表情的辨别力，提出一种新的基于 Laplacian 的特征选择方法，在已发表的数据集中得到了很好的识别效果^[41]。Wang 等人提出了一种紧实的 LBP-TOP 描述符 (Super-compact LBP-Three Mean Orthogonal Planes, MOP)，MOP 所描述的紧实鲁棒形式不仅保留了基本模式而且减少了影响编码特征判别的冗余^[42]。Hong 等人为提高 LBP-TOP 在时空信息上的计算效率，引入了张量的概念，这加速从三维空间到二维空间的实现过程^[43]。

除 LBP 及其变体外，部分研究人员致力于对光流特性的研究。如 Liu 等人提出利用主方向平均光流特征 (Main direction Mean opticflow, MDMO) 进行微表情识别，同时还考虑了局部统计运动和空间位置信息，在 SMIC 和 CASMEII 数据库上都取得了良好的性能，但是他们只使用了 SMIC 的第一个版本，而不是 SMIC 的完整版^[44]。Liong 等人从光学应变量值得到一个时间段内人脸的细微相对位移量，并对局部特征赋予不同的权重，形成新的特征^[45]。Xu 等人利用光流估计对微表情图像序列选择的粒度进行像素级对齐，得到主光流方向，将其作为精细的面部动态特征描述符^[46]。

近年来，对微表情识别的研究十分活跃。到目前为止，大多数提出的方法都考虑使用基于纹理的特性来完成任务。时空纹理特征是描述面部运动的合适选择，但单独使用它们可能不足以进行微表情识别，识别性能仍有很大的提升空间。Li 等人将低强度的微表情视频经过欧拉视频放大，在三个正交平面上利用不同的特征提取符提取特征对微表情进行识别。随后 Li 等人基于 LBP-TOP 的思想在三个正交平面上扩展了梯度方向直方图 (HOG) 和图像梯度方向直方图 (HIGO) 提出了 HOG-TOP 和 HIGO-TOP。Song 等人通过从面部和身体微弱运动中学习的稀疏编码来识别情绪，他们的微表情定义更

加广泛，将身体部位（脸部除外）的姿势包括在内^[47]。Ngo 等人提出了一种用于微表情图像序列预处理的选择性转移机（Selective Transfer Machine, STM），用于解决数据库中不平衡和不同面部形态的问题^[48]。Lu 等人发现微表情的图像序列在时空域中基于 Delaunay 三角归一化，提出了基于 Delaunay 的时间编码模型（Delaunay-based temporal coding model, DTCM）^[49]。Oh 等人通过 Riesz 小波变换获得多尺度单原信号，提取其幅值、相位、方向特征组成新的特征描述符进行微表情识别^[50]。He 等人提出了一种多任务的中层特征学习方法进行特征提取，该方法能够获得更具识别能力和泛化能力的中层特征^[51]。由于深度学习模型需要大量的数据进行训练，而现有的微表情数据还远远不够，但最近，Patel 等人提出了一种利用深度学习模型解决微表情识别问题的方法^[52]。作者建议选择性使用基于普通人脸表情数据库训练的卷积神经网络（Convolutional Neural Networks, CNN）模型的深度特征，但效果并不理想。Li 等人发现微表情的峰值帧能够表达更丰富的情感，他们提出了一种在峰值帧应用深度神经网络的方法检识别表情，在 CASME II 上取得了不错的成果^[53]。表 1 对目前提出的大多数方法做了列举。

表 1 微表情的研究方法

摆拍微表情数据集（Posed）		自发微表情数据集（Spontaneous）	
微表情检测	微表情识别	微表情检测	微表情识别
3D 梯度	Gentleboost 和 SVM	特征差异与峰值检测	TIM+MKL+LBP-TOP+RF 二阶高斯射流的再参数化 从张量独立色彩空间中提取 LBP-TOP 局部时空方向特征 + 鲁棒 PCA 低强度的微表情视频经过欧拉视频放大 基于普通表情的迁移学习 LBP-SIP、STM、MOP、STCLQP、DTCM Riesz 小波变换、光流估计
Gabor 滤波器			引入张量概念的 Fast LBP-TOP MDMO+ 局部运动 + 空间位置 HOG/HIGO-TOP
应变的光流方法	人脸与身体微弱运动结合	基于概率的随机游走模型	

1.3 本文的研究内容

本文简单介绍了微表情识别的研究现状和基本方法，以及其不容小觑的应用价值。然而，目前的微表情研究都是基于高质量数据集的基础上展开的，例如 SMIC 数据集的人脸分辨率为 190×230 像素，最新发布的 SAMM 数据集的人脸分辨率达到 400×400 像素之高，但在实际应用中由于图像采集设备的机能限制，难免会遇到低像素的视频数据，这严重影响了几乎所有的微表情识别算法的性能，为了解决这一问题，本文提出了专门针对低分辨率环境下的微表情识别方法：按照常规方法对视频做预处理，然后再使用超分辨率重建技术从低维图像中近似的重建出高维图像，对重建出的高维图像进行微表

情识别，最后比较重建后的微表情识别效率与未重建前的低维图像的识别效率，同时分别从传统机器学习和深度学习两个角度介绍了系统框架和识别结果。

本文共分为六章，内容具体安排如下：

第一章：绪论。阐述了微表情研究的背景及意义，概括了国内外最新的微表情研究现状，最后对文章的整体结构做出安排；

第二章：相关工作。简单介绍了微表情的概念和微表情数据集，总结了微表情识别在传统方法和深度学习方法的进展，阐述了低分辨率微表情的识别的意义和最新进展；

第三章：基于传统方法的低分辨率环境下微表情识别的研究。主要介绍了人脸对齐与分割，其中包括对单一目标检测中主动形状模型（Active Shape Model, ASM）准确度的算法改进，图像序列的超分辨重建，LBP-TOP 和 SVM；

第四章：基于深度学习的低分辨率环境下微表情识别的研究。主要介绍了伪 3D 残差网络（Pseudo-3D Residual Networks, P3D ResNet），数据增强以及实验分析；

第五章：低分辨率环境下微表情识别可视系统。通过对需求分析设计出系统的时序图和功能图，最后设计出功能完善的可视化系统；

第六章：总结与展望。总结全文的工作，分析不足和展望未来前景。

第二章 相关工作

本章的主要内容分为三个部分，第一部分主要介绍微表情研究中使用的数据集以及微表情和常见的宏表情之间的差异，第二部分介绍近几年微表情研究中所使用的特征提取的几种方法，第三部分介绍本文将在第四章中使用的相关深度网络的基础知识。

2.1 宏表情和微表情

普通的人脸表情可以是自然产生的，也可以是根据需要人为的摆拍出来。摆拍的人脸表情是有意表现出某种情绪，而自然产生的人脸表情是在表达自己的真实情感。所以在人脸宏表情（普通人脸表情）的研究中，既有自然产生的表情数据，也有摆拍的表情数据，微表情研究也存在类似的问题。在微表情研究领域用“自发”这个词来强调微表情的产生（或被诱导）是自然的，因为参与者的内心存在实际的情感。

所以根据表情的产生方式将微表情分为“自发”产生的自然微表情和“摆拍”的微表情。目前摆拍的数据集主要有 USF-HD 数据集和 Polikovsky 数据集，自然状态下诱发产生的自发数据集，主要包括 SMIC、SMIC2、CASME、CASME II 和 SAMM 等数据集，本节将简单介绍几种数据集的产生方式和优缺点，同时列举典型的宏表情数据集做对比，明确微表情的概念。

2.1.1 宏表情数据集

随着图像识别和表情研究的深入，宏表情数据集的建立越来越完备。目前常用的人脸宏表情数据集有日本女性表情库（The Japanese female facial expression, JAFFE）^[54]、Yale 表情数据集^[55] 和 CK+ 人脸表情数据集^[56] 等。本文提出的算法中没有用到宏表情，此处以最常用的 CK+ 数据集举例只为说明宏表情和微表情之间的差异。

CK+ 数据集是在 Cohn-Kanade Dataset 的基础上扩展来的，发布于 2010 年。2000 年，Cohn-Kanade（CK）数据集发布，目的是促进人脸面部表情的自动检测研究。从那时起，CK 数据集成为算法开发和评估中使用最广泛的测试平台之一。在此期间，产生了三个明显的局限性：1) 虽然 AU 编码经过了很好的验证，但是情感标签是错误的，因为标定的标签是被要求的，而不是实际产生的；2) 对新算法的评估缺乏一个通用的性能指标；3) 不包含常见数据集的标准协议。因此，CK 数据集被用于 AU 和情感检测时缺少与基准算法的比较，并且使用原始数据集的随机子集使得对元数据的分析变得困难。为了解决这些问题，发布了扩展版的 Cohn-Kanade 数据集 CK+。CK+ 数据集中的表情分为三类，包括了摆拍和自发的表情以及其他类型的元数据（Metadata）。对于摆拍的表情，序

列的数量比第一版的增加了 22%，参与者的数量增加了 27%。与初始版本一样，每个序列的目标表情都是完整的 FACS 编码，情感标签也经过了修改和验证。此外，元数据中还添加了经过验证的情感标签。数据集中还包含使用主动外观模型（Active Appearance Models, AAMs）和线性支持向量机分类器给出的基线结果，使用留一法交叉验证对摆拍的数据进行 AU 和情绪检测。

CK+ 数据集包括 123 个参与者，593 个图像序列，每个图像序列的最后一张帧有 AU 标签，而在这 593 个图像序列中，有 327 个序列有情感标签。CK+ 数据集是人脸表情识别中比较流行的一个数据集，该数据集将情感分为 8 类，包括中性，厌恶，愤怒，蔑视，压抑，快乐，悲伤，惊讶。图 1 给出了该数据集中的样本图片。综合来说，CK+ 是目前较为理想的表情数据集。

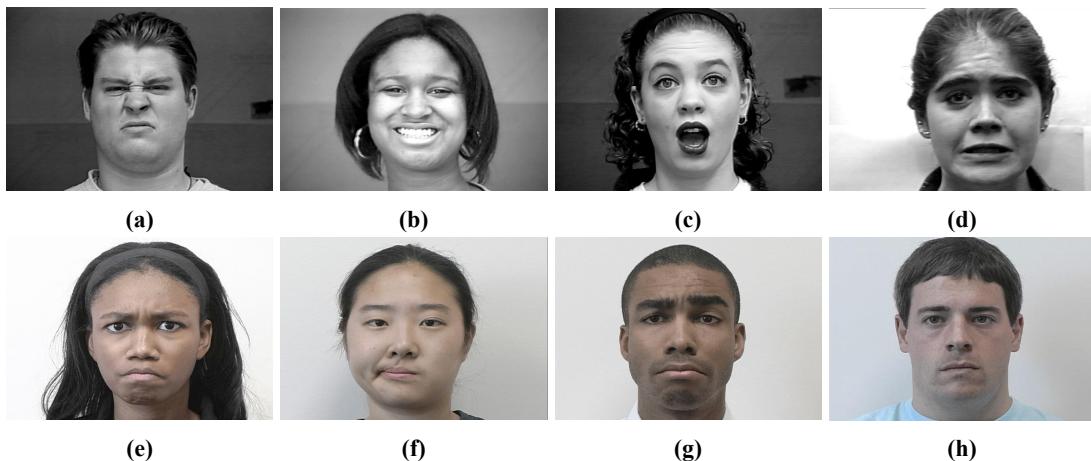


图 1 人脸宏表情样本示例（CK+ 数据集）

(a) 厉害、(b) 快乐、(c) 惊讶、(d) 压抑、(e) 生气、(f) 蔑视、(g) 厉害、(h) 中性表情

2.1.2 早期微表情数据集

由于微表情在镜头下很难产生，所以微表情数据的缺乏是微表情研究的第一障碍。虽然微表情已经被心理学家研究了很长一段时间，但网络上广泛传播的微表情样本仅仅只有片段，并没有发现任何心理学研究小组分享的大数据集。作者认为第一个原因是心理学研究更关注微表情本身的性质，比如什么时候出现或者看起来是什么样子，所以他们不需要像使用计算机研究那样需要大量的微表情数据。其次，在某些情况即使涉及到大量的微表情数据，但由于保密性限制，数据无法公开共享，例如患者的病历或司法讯问记录等。

以 2009 年为时间点，在此以前属于微表情的早期研究阶段，一些研究人员在他们的研究中使用了摆拍的微表情数据，这些数据避免了自发微表情数据获取时的困难，作为早期自动微表情识别研究的尝试，使用摆拍的数据是一次历史性的突破。例如 Shreve 等人收集了一个名为 USF-HD 的数据集，其中包含 100 个摆拍的微表情片段，视频长度

平均在 1 分钟左右，最长 2 分钟，最短 20 秒。研究人员要求参与者模仿屏幕上显示的微表情样本作为数据的来源，同时在他们的文章中明确写到可以通过要求参与者尽可能快地模仿来收集一个摆拍的微表情数据集。Polikovsky 等人也收集了一个摆拍的微表情数据集，要求受试者在低强度下表演七种基本情绪，并尽快回到中性表情，数据由一台每秒 200 帧的高速摄像机记录。表 2 列出了摆拍的微表情数据集的详细属性。

表 2 摆拍微表情数据集

	USF-HD	Polikovsky
微表情片段	100	N/A
参与者	N/A	10
分辨率	720 × 1280	480 × 640
FPS	29.7	200
FACS	NO	YES
表情类	N/A	7
人种	N/A	3

值得注意的是摆拍的微表情数据不可以代替或与自发的微表情数据一起使用，因为这两种数据是不同性质的。例如在研究微表情的起始点时，由于两者是在不同的机制下产生的，所以摆拍的微表情在时空特性上与自发的微表情存在很大的差异，其次在研究视频的上下文时，由于模仿的表情与通过视频编辑生成的摆拍微表情片段通常在起止点很突兀，而且期间禁止其他无关的动作发生，这也与自发的微表情有很大的不同。另一方面，自然环境下自发的微表情可能伴随着复杂的场景，比如头部运动和眨眼等动作。基于这些事实，利用摆拍的微表情数据进行研究并不能真正解决实际中微表情分析的自动化问题，所以努力收集自发的微表情数据是后续工作的正确路径。需要说明的是在本文接下来的内容中，所有的工作都是关于自发微表情的，如果没有特别说明，“微表情”一词表示自发微表情。

2.1.3 自发微表情数据集

A. SMIC 数据集介绍

2011 年，论文 [32] 首次提出了一种诱导和收集自发微表情的方法，将获得的数据集命名为“自发微表情语料库”，简称 SMIC，它是第一个使用自然诱发状态的微表情数据集，对后续的数据集建立具有很好的指导性意义。第一版的 SMIC 数据集只包含了 6 位参与者的数据，论文 [21] 对其进行了扩充，包含了 16 名参与者的 164 个自发微表情片段，由三种相机记录的 3 个数据集组成：100fps 的高速相机记录的 HS 数据集、25fps 的普通彩色相机记录的 VIS 数据集和 25fps 的近红外摄像机记录的 NIR 数据集，且所有数据集具有相同的图像分辨率 640×480 。增加 VIS 和 NIR 摄影机有三个考虑：(1) 提升

数据集的多样性；(2) 研究高速相机在微表情分析方面是否优于普通速度相机；(3) 研究时间插值方法是否可以应用于普通高速相机，以解决相机的短时插值问题。图 2 给出一个消极的微表情序列，通过该样例可以看出，一个微表情是由一组图片序列构成的，本样例的变化主要表现为嘴角的细微下沉。

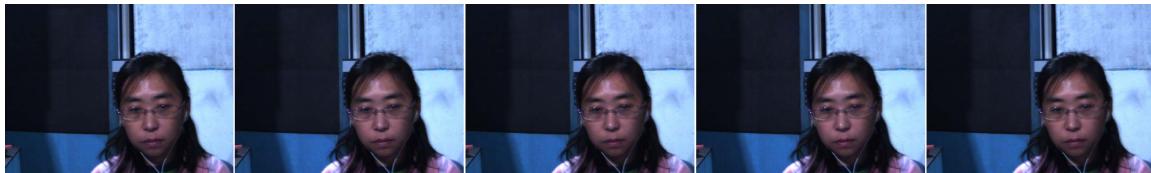


图 2 一个消极的微表情片段示例 (SMIC 数据集)

a) 视频采集

研究表明通过图像、视频和音乐等一定的刺激能够诱发真实的表情^[57]。自发微表情是由人的内心感受触发的非自愿行为，所以可以使用上述方法引发情感反应。但必须找到一种能确保诱发的表情足够短的方法（满足微表情的标准）。一些心理学著作研究了微表情发生的条件，Ekman 等人认为当人们试图隐藏自己的真实情感时，尤其是当被抓住后果会很严重时，微表情就会出现，这被称为高风险条件，例如嫌疑人正在接受警察或测谎专家的审问，这是一种很自然的高风险场景。但是对于采集数据而言，营造真正的审问现场显的不太可能。所以为了诱导参与者自发的微表情，需要找到一种模拟高风险环境的方法。设计的情景必须满足以下两个要求：(1) 激发参与者情绪的刺激必须有效，使激发的情绪反应强烈到无法完全隐藏；(2) 应该制造高压力，这样参与者才会有动力去尽力隐藏自己的真实感受。

作者使用了心理学研究中诱导抑制情绪产生的方法。采集前向参与者详细说明研究内容和过程，显示器上显示如下提示性语句：“(1) 将向您展示几段诱发情绪的短片，请尽量保持头部稳定并仔细观看。(2) 每段视频片段后，您将有一个短暂的休息。请根据您对刚才看到的视频的真实感受填写调查表（报告中的情感反馈是标注过程中的重要参考。)。(3) 当您在看视频的时候，我会待在另一个房间，通过摄像头观察您的面部和身体动作，并尝试猜测您所看的视频片段(片段是随机播放的)。您的任务是装出若无其事的样子，而不是表露您的真实感情。如果您不能隐藏您的感觉，您将不得不填写一份超过 500 个冗长而乏味的问题问卷。”

在每段影片结束后，参与者将在问卷中回答以下问题：“(1) 您在看视频时感受到了什么样的情绪(快乐、悲伤、厌恶、压抑、惊讶、愤怒或困惑)？(2) 看视频的时候您是否感觉到愉悦？(从 1 到 7 愉悦程度逐渐上升)”。选择最有效的刺激作为情感诱导因子是后续数据采集的关键因素之一。通过查阅文献比较不同类型的情绪诱导材料，如图

像、音乐、视频和互动。最终决定使用短视频作为微表情采集诱导剂的原因有三个：(1) 视频包含音频和视觉信息，因此比图像和音乐的影响更强大；(2) 视频能够持续一段时间，更能激发强烈情绪，更容易产生微表情；(3) 从获取稳定额叶面部视频的实际角度来看，观看视频的参与者比多人参与的互动场景更容易控制。

20 名来自奥卢大学的学生和研究人员自愿参与数据集的制作，参与者的年龄从 22 岁到 34 岁不等，其中 7 位是女性，13 位是男性，9 人是白种人，11 人是亚洲人。研究人员在电脑显示器上向参与者展示了 16 段精心挑选的能引发强烈情绪的视频片段。当参与者观看视频片段时，三个固定在电脑显示器上的摄像头记录参与者的面部反应，操作人员在前方通过另外一台电脑监控参与者的面部反应，图 3 给出了环境设置示意图。



图 3 微表情数据采集示意图

b) 视频的标注

录制的视频需要进行分割和标注，目的是得到适合研究人员进行训练与测试的微表情样本和相应的标签。采集的三种视频中高速视频由于具有最佳的时间分辨率所以非常适合标注，另外两个摄像头拍摄的视频需要同步后再进行标注。首先，从原始的长视频中分割出微表情的起始和终止帧，微表情序列的开始表示的是与之前中立(或接近中立)的人脸表情相比的可见运动的第一帧，而微表情序列的终止指在与下一帧相比可以发现任何运动时结束的最后一帧。关于微表情精确的长度限制目前还存在争议，SMIC 数据集参考论文 [6] 和 [7] 等人的建议，设置了 1/2 秒较宽松的分割节点。注意，并不是所有的微表情都结束于一个完全的中性表情，有些表情可能会上升，然后下降到接近中性的状态，并保持这种状态很长时间，这也被认为是微表情的结束。

随后，对所有的视频片段都用情感标签进行标注。情感标签的证据有两种：视频片段的内容和参与者提交的报告。虽然在视频播放前已经预知将可能产生某种确定情绪，但研究发现，参与者在某些视频刺激下可能会产生不同的情绪表现(甚至相反的情

绪)。在少数情况下,当参与者提交的问卷报告与视频内容相反时(例如,一些参与者反馈在观看恐怖视频片段时感到快乐或有趣),SMIC数据集使用参与者的提交的报告作为微表情标签的标准。起初,SMIC数据集根据视频内容分配了五种情感标签,包括快乐(Happy)、悲伤(Sad)、恐惧(Fear)、厌恶(Disgust)和惊讶(Surprise)。后来,SMIC数据集将五类标签合并为三类:积极(Positive)、惊讶(Surprise)和消极(Negative)。将第一版本的快乐类别改为新的积极类别,而消极类别则是由第一版的悲伤、恐惧和厌恶这三个类别组合而成。将三种消极情绪融合在一起的原因是:首先,参与者在该段视频的报告中选择了三种情绪中的一种以上;其次,三种标签的样本量都太小,合并后会更好的平衡。根据具体情况,惊讶类别可以分为积极惊讶和消极惊讶。同时为了验证数据标签的有效性,标注由两位标注者分别执行。然后,两位标注者相互交换检查各自的标注,只有当两位标注者的标注结果一致时的标签有效。

B. CASME 数据集介绍

在SMIC发表后不久,另一组研究人员收集了新的自发微表情数据集。由中国科学院Yan等人采用与SMIC相似的情绪诱导方式收集了中国科学院微表情数据集(CASME),包含19位中国籍参与者的195个微表情片段。CASME由两台相机记录,一台是明基M31相机,帧率为60fps,分辨率为 1280×720 (CASME-A),另一台是灰点GRAS-03K2C相机,帧率为60fps,分辨率为 640×480 (CASME-B)。CASME数据集中的微表情首先使用AU标记,然后被分为八类情绪,包括娱乐(Amusement)、悲伤(Sadness)、厌恶(Disgust)、惊讶(Surprise)、蔑视(Contempt)、压抑(Repression)、恐惧(Fear)和紧张(Tension)。之后又发布了第二版数据集CASME II,CASME II提供了更多具有更高时空分辨率的微表情样本。新数据集的平均人脸尺寸为 280×340 ,每秒200帧,是从26名中国参与者中获得的247个微表情样本。CASMEII样本有五个类的AU标签和情感标签,即开心(Happiness)、厌恶(Disgust)、惊讶(Surprise)、压抑(Repression)和其他(Others)。

CASME II数据集相比之前的数据集引入了AU标签,它是在充分考虑了主客观因素(除了FACS编码的基本判断)外,还参考了参与者自己的主观回忆来辅助标注的样本标签。除此之外,该数据集还对微表情的起始帧、峰值帧和终止帧都做了详细的标注。

C. 其他数据集介绍

最近又有一个新的自发微表情数据集SAMM发布,它也使用了类似于SMIC和CASME的情绪诱导方法,从13个不同民族的32名参与者中获得159个微表情。SAMM数据具有更高的帧分辨率 2040×340 ,帧速率为200fps。数据提供了AU标签和八种表情标签,包括开心(Happiness)、惊讶(Surprise)、悲伤(Sadness)、生气(Anger)、恐

惧 (Fear)、厌恶 (Disgust)、蔑视 (Contempt) 和其他 (Other)。

表 3 列出了当前所有提到的微表情数据集的详细参数。

表 3 自发微表情数据集

	SMIC-HS	SMIC-subHS	SMIC-NIR	SMIC-VIS	CASME II	SAMM
微表情片段	164	71	71	71	247	159
参与者	16	8	8	8	26	32
分辨率	640 × 480	640 × 480	640 × 480	640 × 480	640 × 480	2040 × 1088
人脸分辨率	190 × 230	190 × 230	190 × 230	190 × 230	280 × 340	400 × 400
FPS	100	100	100	100	200	200
性别比 (F/M)	6/10	2/6	2/6	2/6	15/11	16/16
FACS	NO	NO	NO	NO	YES	YES
表情类	3	3	3	3	5	8
平均年龄 (SD)	26.7 (N/A)	26.7 (N/A)	26.7 (N/A)	26.7 (N/A)	22.03 (SD=1.6)	33.24 (SD=11.32)
人种	2	2	2	2	1	4

2.1.4 宏表情与微表情比较

通过前两小节的介绍可以看出微表情和宏表情最大的区别是在面部肌肉的运动强度和持续时间。如图 4 所示，人脸根据不同的部位被划分为不同的肌肉组如皱眉肌、降眉间肌、鼻肌等，图 1 中上述肌肉运动明显比图 2 更加剧烈也更加夸张；另一方面，微表情的持续时间一般在 1/25 秒到 1/2 秒之间，而宏表情则不然。

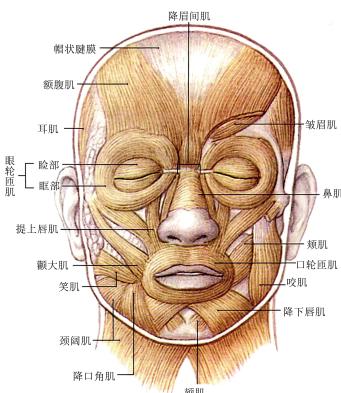


图 4 人脸面部表情肌肉划分

目前存在的宏表情和微表情数据集种类繁多且各具特色，但因为各类研究目的的差异，各类数据集间的迁移效果并不显著，存在着很大的局限性和个体差异性，存在的问题集中表现为以下几点：

首先，各个数据集建立标准不统一。对于常用的宏表情数据集，例如 JAFFE 和 CK+ 两个宏表情数据集，他们在情感分类的标准上存在差异，JAFFE 数据集将表情分为快乐、愤怒、厌恶、讨厌、惊讶、压抑和中性七类，而 CK+ 数据集则在此基础上加入了轻

蔑。同样与微表情数据集的分类方式也不一样，例如 SMIC 微表情数据集将表情分类为积极、消极和惊讶三类，CASME 系列数据集将表情分类高兴、惊讶、悲伤、厌恶、恐惧、压抑和其他七种类型。另一方面，对于微表情数据集，不同的数据集之间诱发方式可能也存在差异，例如有的数据集使用自然诱发（SMIC、CASME），有的使用非自然状态下的模拟方式（USF-HD、Polikovsky）。此外差异性还表现在 SMIC 数据集没有对 AU 单元进行标注、CASME 数据集的光照条件为。所以不同的数据库建立标准导致了难以使用统一的方法对数据集进行性能的评价。

其次，样本数量有限。目前各个数据集的样本数量较少，尤其是参与者的数量有限，这使得某些微表情现象不具有普遍意义，同时也难以提出较强的可说服性理论。

2.2 微表情特征提取的一般方法

2.2.1 基于纹理信息的 LBP-TOP 特征提取符

局部二值模式（Local Binary Pattern, LBP）是一种用来描述图像局部纹理特征的运算符，它具有旋转不变性和灰度不变性等显著的优点，在人脸识别方面被广泛应用^[58]。简单来说，就是对图像中的某一像素点的灰度值与其邻域的像素点的灰度值做比较，如果邻域像素值比该点大，则赋为 1，反之，则赋为 0。从图像的左上角开始，形成一个 LBP 编码，然后将该编码转换为一个十进制数。通过这种转换，可以将一个像素点与邻域的差值关系用一个数表示。

因为 LBP 特征记录的是像素点与邻域像素的差值关系，所以光照变化只会引起像素值的同增或同减，不会改变 LBP 值的大小，特别是在局部区域，所以 LBP 可以很好的保存图像中像素值的差值关系（如图 5 所示）。进一步的将 LBP 做直方图统计，这个直方图就可以用来作为纹理分析的特征算子。

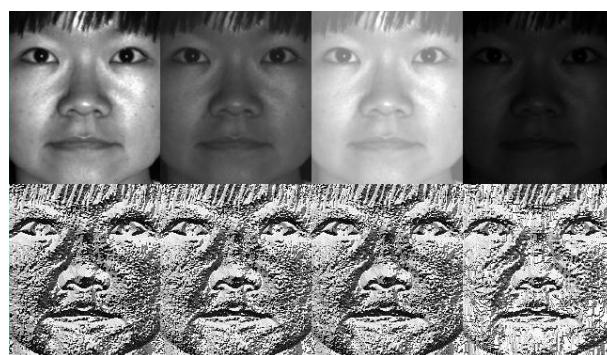


图 5 LBP 特征的光照鲁棒性

但是 LBP 只能处理单张的二维图像，对于视频或者图像序列则无能为力，2007 年芬兰奥卢大学的 Zhao 等人提出了一种处理动态纹理的 LBP 特征提取符 LBP-TOP，但

是现在已经被广泛用于基于视频的人脸表情识别^[59]。

LBP-TOP 是 LBP 从二维空间到三维空间的拓展，是在二维图像的 X、Y 方向上增加了一个沿着时间方向的 T 轴，形成了互相正交的 XY、XT 和 YT 三个平面。以一个图像序列为单位组成一个立方体，对其划分合适的块参数（Blocksize），将一个小块作为一个小单元从三个不同的平面提取 LBP 特征生成该平面的特征直方图，将三个直方图级联为一个基于块的直方图，以同样的方式遍历整个图像序列立方体，生成最终的 LBP-TOP 特征直方图，如图 6 所示，中间的三列直方图是小单元的 LBP-TOP 特征直方图，右侧的直方图是整个立方体的 LBP-TOP 特征直方图，关于 Blocksize 的划分将在章节三中讨论。

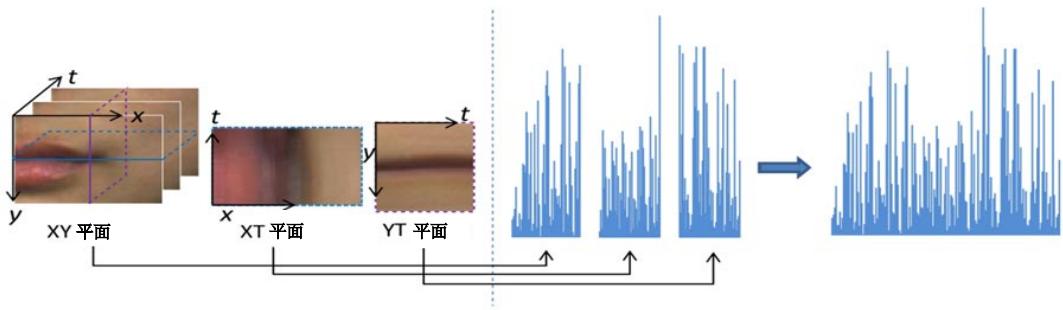


图 6 LBP-TOP 特征提取过程

2.2.2 基于光流法的特征提取

二十世纪五十年代心理学家 Gibson 在其著作 [60] 中首次提出了环境光（Ambient optic）、环境光阵（Ambient optic array）、光流（Optic flow）和光流阵（Optic flow array）等基本概念。随后，一系列关于昆虫视觉机理方面的实验结果表明，大多数昆虫都可以通过光流测量自身的运动，进而通过积分获得自身飞行的距离。1976 年，Poggio 和 Reichardt 等人在研究昆虫视觉时提出了关于光流的粗略计算形式^[61]，1981 年 Horn 和 Lucas 等人将二维速度场与灰度相联系，引入了光流约束方程，为光流计算做出了奠基性的工作^[62,63]。

光流是空间运动物体在观察成像平面上的像素运动的瞬时速度，是利用图像序列中像素在时间域上的变化以及相邻帧之间的相关性来找到上一帧跟当前帧之间存在的对应关系，从而计算出相邻帧之间物体的运动信息的一种方法。一般而言，光流是由于场景中前景目标本身的移动、相机的运动，或者两者的共同运动所产生的。Barron 等人对多种光流计算技术进行了总结，按照理论基础与数学方法的区别把它们分成四种：（1）基于区域或者基于特征的匹配方法；（2）基于频域的方法；（3）基于梯度的方法；（4）基于能量的方法^[64]。光流的研究是利用图像序列中的像素强度数据的时域变化和相关性来确定各自像素位置的“运动”，即研究图像灰度在时间上的变化与景象中物体结构

及其运动的关系，将二维图像平面特定坐标点上的灰度瞬时变化率定义为光流矢量。光流场（optical flow field）是运动场在二维图像平面上的投影（运动场，物体在三维真实世界中的运动），是一个二维矢量场，包含的信息是图像中像素点的灰度值发生变化趋势的瞬时速度矢量信息，那通俗的讲就是通过一个图像序列，把每张图像中每个像素的运动速度和运动方向找出来就是光流场。研究光流场的目的就是为了从图像序列中近似计算出不能直接得到的运动场。图 7 提供了光流场中光流的大小和方向的表现。

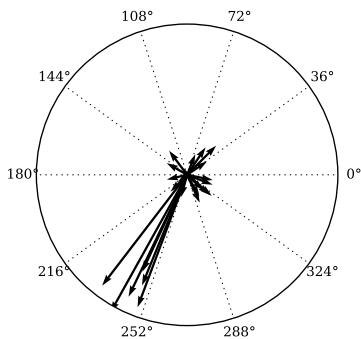


图 7 光流大小和方向的表现

光流法检测运动目标，其基本思想是赋予图像中的每一个像素点一个速度矢量，从而形成了该图像的运动场。图像上的点和三维物体上的点在某一特定的运动时刻是一一对应的，根据各像素点的速度矢量特征对图像进行动态的分析。若图像中不存在运动目标，那么光流矢量在整个图像区域则是连续变化的，而当物体和图像背景中存在相对运动时，运动物体所形成的速度矢量则必然不同于邻域背景的速度矢量，从而将运动物体的位置检测出来。但光流法的计算过于复杂，而且在实际情况中由于各种复杂的环境因素常常会导致计算结果出现很大的误差，故对它的使用必须是在建立一定前提假设的基础上的：（1）相邻帧之间保持亮度恒定不变；（2）相邻帧的取帧时间保持连续或物体运动幅度小；（3）具有空间一致性，同一子图的像素点具有相同的运动。

光流不能由运动图像的局部信息来唯一的确定，例如，亮度等值线上的点或者亮度比较均匀的区域都无法唯一的确定其点的运动对应性，但是运动是可以进行观察得到。当人的眼睛观察运动物体时，物体的景象在人眼的视网膜上形成一系列连续变化的图像，这一系列连续变化的信息不断“流过”视网膜（即图像平面），由于它包含了目标运动的信息，因此可被观察者用来确定目标的运动情况。由此说明运动场和光流不一定是唯一对应的，即光流不一定是由物体运动产生的，反之如果物体发生了运动也不一定能产生光流。但是一般情况下，表观运动和物体真实运动之间的差异是可以忽略的，可以用光流场代替运动场来分析图像中的运动目标及其相关的运动参数。

2.2.3 基于 Gabor 的特征提取

Gabor 小波与人类视觉系统中简单细胞的视觉刺激响应非常相似，它在提取目标的局部空间和频率域信息方面具有良好的特性^[65,66]。虽然 Gabor 小波本身并不能构成正交基，但在特定参数下可构成紧框架。Gabor 小波对于图像的边缘敏感，能够提供良好的方向选择和尺度选择特性，而且对于光照变化不敏感，能够提供对光照变化良好的适应性。上述特点使 Gabor 小波被广泛应用于视觉信息理解。二维 Gabor 小波变换是在时频域进行信号分析处理的重要工具，其变换系数有着良好的视觉特性和生物学背景，因此被广泛应用于图像处理、模式识别等领域。与传统的傅立叶变换相比，Gabor 小波变换具有良好的时频局部化特性。即非常容易地调整 Gabor 滤波器的方向、基频带宽及中心频率从而能够最好的兼顾信号在时空域和频域中的分辨能力；Gabor 小波变换具有多分辨率特性即变焦能力。即采用多通道滤波技术，将一组具有不同时频域特性的 Gabor 小波应用于图像变换，每个通道都能够得到输入图像的某种局部特性，这样可以根据需要在不同粗细粒度上分析图像。此外，在特征提取方面，Gabor 小波变换与其它方法相比：一方面其处理的数据量较少，能满足系统的实时性要求；另一方面，小波变换对光照变化不敏感，且能容忍一定程度的图像旋转和变形，当采用基于欧氏距离进行识别时，特征模式与待测特征不需要严格的对应，故能提高系统的鲁棒性。

无论从生物学的角度还是技术的角度，Gabor 特征都有很大的优越性。研究表明，在基本视觉皮层里的简单细胞的感受野局限在很小的空域范围内，并且高度结构化。Gabor 变换所采用的核与哺乳动物视觉皮层简单细胞 2D 感受野剖面非常相似，具有优良的空间局部性和方向选择性，能够抓住图像局部区域内多个方向的空间频率（尺度）和局部性结构特征。这样，Gabor 分解可以看作一个对方向和尺度敏感的有方向性的显微镜。同时，二维 Gabor 函数也类似于增强边缘以及峰、谷、脊轮廓等底层图像特征，这相当于增强了被认为是面部关键部件的眼睛、鼻子、嘴巴等信息，同时也增强了诸于黑痣、酒窝、伤疤等局部特征，从而使得在保留总体人脸信息的同时增强局部特性成为可能。它的小波特性说明了 Gabor 滤波结果是描述图像局部灰度分布的有力工具，因此，可以使用 Gabor 滤波来抽取图像的纹理信息。由于 Gabor 特征具有良好的空间局部性和方向选择性，而且对光照、姿态具有一定的鲁棒性，因此在人脸识别中获得了成功的应用。然而，大部分基于 Gabor 特征的人脸识别算法中，只应用了 Gabor 幅值信息，而没有应用相位信息，主要原因是 Gabor 相位信息随着空间位置呈周期性变化，而幅值的变化相对平滑而稳定，幅值反映了图像的能量谱，Gabor 幅值特征通常称为 Gabor 能量特征 (Gabor energy features)。Gabor 小波可像放大镜一样放大灰度的变化，人脸的一些关键功能区域(眼睛、鼻子、嘴、眉毛等)的局部特征被强化，从而有利于区分不同的人脸图

像。Gabor 小波核函数具有与哺育动物大脑皮层简单细胞的二维反射区相同的特性，即具有较强的空间位置和方向选择性，并且能够捕捉对应于空间和频率的局部结构信息；Gabor 滤波器对于图像的亮度和对比度变化以及人脸姿态变化具有较强的健壮性，并且它表达的是对人脸识别最为有用局部特征。Gabor 小波是对高级脊椎动物视觉皮层中的神经元的良好逼近，是时域和频域精确度的一种折中。

通过上面的分析，我们知道一个 Gabor 核能获取到图像某个频率邻域的响应情况，这个响应结果可以看做是图像的一个特征。那么，我们如果用多个不同频率的 Gabor 核去获取图像在不同频率邻域的响应情况，最后就能形成图像在各个频率段的特征，这个特征就可以描述图像的频率信息了，由于纹理特征通常和频率相关，因此 Gabor 核经常用来作为纹理特征。

2.3 相关深度学习网络

深度学习方法作为机器学习尤其是神经网络方法的一种，在图像处理、视频分析和语音识别等领域产生了许多成功的案例。端到端的神经网络模型能够通过学习大量高维数据进行分类和预测，这减少了人工特征工程的繁杂操作。卷积神经网络作为应用最广泛的深度学习方法之一，目前在很多图像相关领域都处于无可替代的地位。卷积神经网络最早出现在论文 [67] 的研究中，在过去的几年里，卷积神经网络经过了大量的分层、分块等设计的修改，诞生了许多成功的衍生网络如 AlexNet^[68]、VGG-Net^[69] 和 GoogLeNet^[70] 等。最近，有很多将深度学习应用于微表情识别的研究，然而，由于是在小数据集上使用的深度网络，所获得的识别准确度仅在随机水平左右。

2.3.1 三维卷积神经网络

二维卷积神经网络被认为是解决图像识别问题的一种强大的模型，但将二维卷积神经网络应用到视频中却并非易事，在视频中应用二维卷积神经网络一个简单的方法就是对每一帧运用卷积来识别，但是这种方法并没有考虑到连续帧间的时间维度信息。一些研究表明，三维卷积能够从空间和时间两个维度提取特征，从而获取多个相邻帧中编码的运动信息。三维卷积神经网络从输入帧中生成多个通道的信息，并结合所有通道的信息得到最终的特征表示。该方法应用到现实环境中的人类行为识别中，在不依赖于人工提取的特性的情况下取得了优异的性能^[71]。

三维卷积是通过将一个三维核与叠加在一起的多个连续帧形成的立方体进行卷积来实现的。在这个结构中，卷积层中每一个特征映射都会与前一层中多个相邻的连续帧相连，从而获取运动信息。需要注意的是：三维卷积核只能从立方体中提取一类特征，因为在整个立方体中卷积核的权值都是一样的，也就是共享权值。所以我们可以采用

多种卷积核，以提取多种特征。对于卷积神经网络有一个通用的设计规则，在后面的层（离输出层近的）特征映射的个数应该增加，这样就可以从低级的特征映射组合产生更多类型的特征。

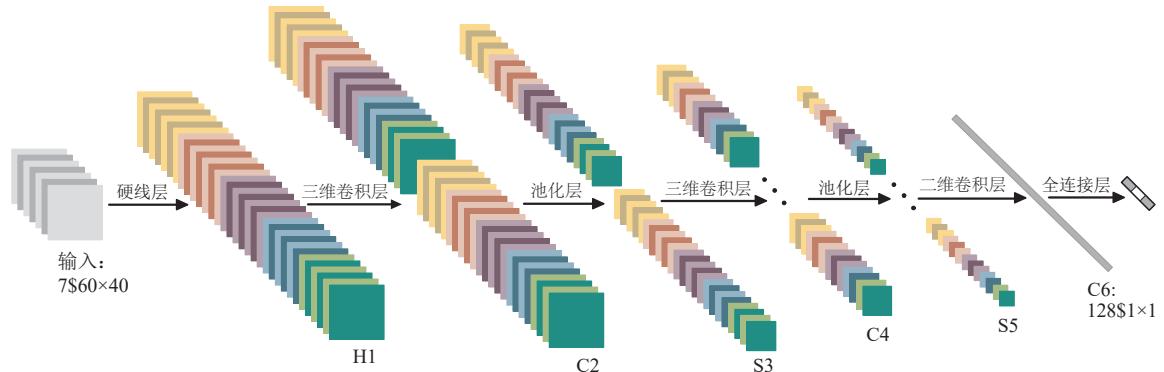


图 8 三维卷积神经网络架构

如图 8 所示，该架构包含一个硬线层、三个卷积层、两个池化层和一个全连接层。每个三维卷积核卷积的立方体是连续的七帧，每帧块大小为 60×40 ；第一层应用了一个固定的硬线核去对原始的帧进行处理，产生多个通道的信息，然后对多个通道分别处理。最后再将所有通道的信息组合起来得到最终的特征描述。

H1 为硬线层 (Hardwired)，每帧提取五个通道的信息，分别是灰度、 x 和 y 方向的梯度， x 和 y 方向的光流。其中，前面三个都可以每帧都计算。然后水平和垂直方向的光流场需要两个连续帧才确定。

C2 为卷积层 (Convolution)，以硬线层的输出作为该层的输入，用一个三维卷积核在五个通道的每一个通道分别进行卷积。同时为了增加特征映射的个数（实际上就是提取不同的特征），在每一个位置都采用两个不同的卷积核。

S3 为池化层 (Sub-sampling)，得到相同数目但是空间分辨率降低的特征映射。

C4 为卷积层，对五个通道分别采用三维卷积核，同样，为了增加特征映射个数，在每个位置都采用三种不同的卷积核。

S5 为池化层，对每个特征映射采用核进行降采样操作，在这个阶段，每个通道的特征映射都很小。

C6 为卷积层，此时对每个特征映射采用二维卷积核进行卷积操作，然后输出为减小到 1×1 大小的特征映射。

经过多层的卷积和下采样后，每连续 7 帧的输入图像都被转化为一个 128 维的特征向量，这个特征向量捕捉了输入帧的运动信息。输出层的节点数与行为的类型数目一致，而且每个节点与 C6 中这 128 个节点是全连接的。最后，采用一个线性分类器来对

这 128 维的特征向量进行分类，实现行为的识别。

2.3.2 残差神经网络

增加网络的宽度和深度可以很好的提高网络的性能，深的网络一般都比浅的的网络效果好，但对于原来的网络，如果简单地增加深度，会导致梯度弥散或梯度爆炸。对于该问题的解决方法是正则化初始化和中间的正则化层（Batch Normalization），这样的话可以训练几十层的网络。虽然通过上述方法能够训练，但是又会出现退化问题。在实验中的表现就是虽然网络层数增加，但在训练集上的准确率却饱和甚至下降了（这个不能简单的解释为过拟合现象，因为过拟合时应该在训练集上表现的更好）。通过浅层网络等同映射构造深层模型，结果深层模型并没有比浅层网络有等同或更低的错误率，推断退化问题可能是因为深层的网络并不是那么好训练，也就是求解器很难去利用多层网络拟合同等函数。

针对这个问题 He 等在 2015 年提出了一种全新的网络，叫深度残差神经网络（Deep residual neural network），它允许网络尽可能的加深，其中引入了全新的结构，如图 9 所示^[72]。

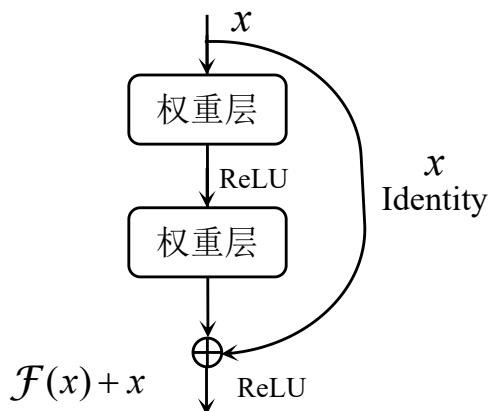


图 9 ResNet 的残差学习模块

理论上，对于“随着网络加深，准确率下降”的问题，ResNet 提出了两种 Mapping：一种是 Identity mapping，指图 9 中的弧线，另一种是 Residual mapping，指除了弧线以外的部分，所以最后的输出是 $y = \mathcal{F}(x) + x$ 。Identity mapping 指自身，也就是公式中的 x ，而 Residual mapping 指的是“差”，也就是 $y - x$ ，所以残差指的就是 $\mathcal{F}(x)$ 部分。如果网络已经到达最优，继续加深网络，Residual mapping 将被转化为 0，只剩下 Identity mapping，这样理论上网络一直处于最优状态了，网络的性能也就不会随着深度增加而降低了。

由上可以看出残差网络 t 的主要思想是在网络中增加了直连通道，即 Highway network 的思想，它允许原始输入信息直接传到后面的层中^[73]，这样的话这一层的神经网

络可以不用学习整个的输出，而是学习上一个网络输出的残差。

传统的卷积网络或者全连接网络在信息传递的时候或多或少会存在信息丢失、损耗等问题，同时还会导致梯度弥散或梯度爆炸，导致很深的网络无法训练。残差网络在一定程度上解决了这个问题，通过直接将输入信息绕道传到输出，保护信息的完整性，整个网络只需要学习输入、输出差别的那一部分，简化学习目标和难度。残差网络的结构可以极快的加速神经网络的训练，模型的准确率也有比较大的提升。残差网络在 ImageNet 比赛分类任务上获得第一名，因为它“简单与实用”并存，之后很多方法都建立在 ResNet50 或者 ResNet101 的基础上完成，检测、分割、识别等领域都纷纷使用残差网络，Alpha zero 也使用了残差网络，所以可见残差网络确实很好用。

第三章 基于传统机器学习方法的低分辨率环境下微表情识别

微表情属于常规性非言语行为，可以真实的表达人类隐藏的情感。它在国家安全、计算机辅助医疗等领域有着非常广泛的应用，这鼓励我们开展微表情自动识别的研究。然而，从监控视频中获取的图像容易出现质量低下等问题，给实际应用带来非常大的困难，使得所有研究都只能在实验层面。由于通过监控视频所捕获图像的质量较低，现有的算法无法达到预期的效果。针对这一问题，我们对低分辨率情况下模糊人脸的微表情识别问题进行了全面的研究并提出了完整的低分辨率环境下微表情识别框架。实验结果表明，该框架在低分辨率情况下的微表情识别中取得了优异的成果。

目前常规的微表情识别算法虽然取得了良好的识别效果，但其性能在很大程度上取决于人脸视频片段的质量。一旦用于识别的人脸视频片段质量较差（如分辨率较低），章节二中提及的算法就无法正常工作。原因主要在两个方面：(1) 低分辨率图像丢失了大量的纹理信息，导致从低分辨率图像序列中提取可用特征变的困难^[74]。(2) 低分辨率图像与高分辨率图像质量（不同分辨率、不同清晰度）不一致，导致我们在测试阶段无法直接使用低分辨率图像作为输入。同时，当处于真实环境时，从监控录像中获取的人脸图像通常只占整个画面的一小部分，例如，用于微表情识别的 SMIC 数据集的人脸分辨率为 190×230 (SMIC 数据集的分辨率为 640×480)。然而更严重的是，常规监控视频捕捉到的图像序列的人脸分辨率往往在 50×50 (或更低) 以下。这意味着之前的微表情识别方法不能直接用于处理低分辨率的情况。因此，对低分辨率环境下的微表情识别的研究具有重要意义和挑战性。

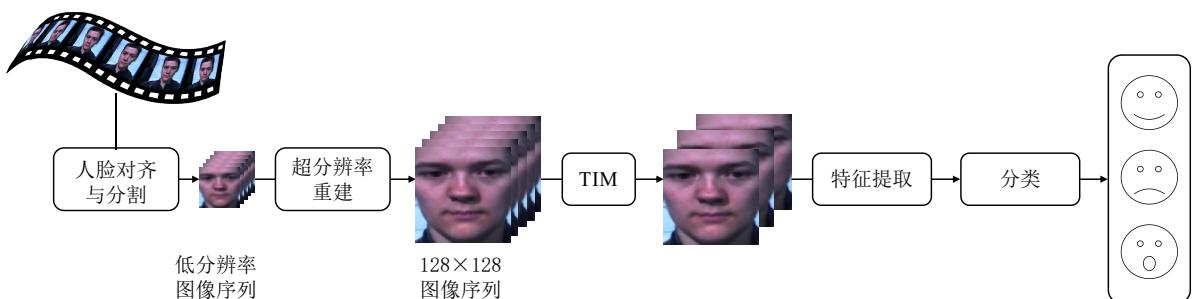


图 10 低分辨率环境下微表情识别框架

为了解决上述问题，我们利用最新的人脸 Hallucination 方法进行了低分辨率微表情识别的研究。我们首先对低质量的人脸图像序列 Hallucination 处理，以近似的重建出丢失的动态特征。然后，我们再采用传统的微表情识别算法识别低质量的微表情图像序列。我们评估了不同分辨率下微表情识别的准确率，研究了分辨率与识别准确率之间的

关系。总的来说，本章的目的是全面研究分辨率对微表情识别的影响，同时提出一个基于传统机器学习方法的处理低质量条件下微表情识别任务的框架。

如图 10 所示，低分辨率微表情识别过程包括图像序列预处理、超分辨率重建、特征提取和分类。详细内容将在本章的以下部分展开描述：

3.1 低分辨率微表情数据获取

目前常用的微表情识别的数据集有很多，如 SMIC 和 CASME 等。然而，这些数据集都是专业相机在严苛环境下获取的高清图像序列，表 3 详细描述了各数据集的参数。图 11 列举了 SMIC-HS 数据集中一个视频片段中的两帧。我们可以在红色框的范围内发现面部表情的细微变化，特别是白色椭圆区域和白色箭头指向的位置运动更为明显。然而，如果图像质量过低，这些细节很难被注意到。



图 11 来自 SMIC-HS 数据集的两帧

由于现有的自发微表情数据集中不存在低分辨率的图像序列，所以我们采用图像退化处理的方法来获得模拟的低分辨率微表情图像序列。论文 [75] 将低分辨率图像分为三大类：小尺寸（Small Size）、低质量（Poor Quality）和小尺寸 & 低质量（Small Size & Poor Quality）。我们考虑第三种类型的图像（小尺寸 & 低质量）作为模拟图像，这样更接近真实应用的情况。

在图像重建任务中，低分辨率图像序列是通过对高分辨率图像序列进行模糊、下采样和噪声处理得到的^[76]，如下式所示：

$$\mathbf{L} = \mathbf{DBH} + \mathbf{n} \quad (3.1)$$

其中 \mathbf{D} 和 \mathbf{B} 分别是下采样和模糊处理， \mathbf{H} 是高分辨率图像， \mathbf{n} 是加性噪声， \mathbf{L} 是低分辨率图像。我们按照公式 3.1 的原理对原始数据处理获得实验所需的低分辨率微表情数据，具体如章节 3.5 的实验部分所示。

3.2 数据预处理

在我们提出的框架中，预处理主要包括三个步骤：人脸对齐、人脸分割和帧插值处理。原始视频中存在自然的姿势变化和无意识的移动，数据集中收集了不同性别、年龄和种族的参与者的微表情视频片段。因此，为了避免上述非表达因素的干扰，进行人脸对齐和人脸分割是必不可少的。同时，由于微表情的强度是非常微弱的，为了减少类内变化和突出微表情运动产生的类间差异，更需要最小化微表情片段间的其他差异（如人脸大小和人脸形状）。为此，我们使用以下描述方式对所有人脸与模型脸对齐处理。

首先，我们选择一个中性的人脸图像作为模型人脸，使用主动形状模型检测模型脸的 68 个人脸关键点，接着对第 i 个微表情片段的第一帧上的人脸检测 68 个关键点，然后使用局部加权平均计算它们之间的关系，对微表情片段的所有帧均使用上述关系进行归一化。最后，将归一化后的图像换算为原始图像的二维变换，根据第一帧中瞳孔的坐标，从每个微表情片段的归一化图像中裁剪出人脸区域。详细过程如下文所示：

3.2.1 主动形状模型

从采集的视频中选取其中没有表情且正面人脸的一帧作为模型脸 \mathbf{I}_{mod} ，手工定位两只眼睛的位置。然后，利用主动形状模型（Active Shape Model, ASM）检测 68 个人脸关键点 $\psi(\mathbf{I}_{mod})$ ^[77]。值得注意的是，传统的 ASM 算法机械地通过检测差异点获取目标，并没有选择目标对错的能力，本章在原算法的基础上增加了条件限定，使得检测的人脸更加准确、规范。如错误标定其他物品或其他人脸（非主要人脸）时，计算任意对应位置关键点的相对距离 $\mathbf{L}(\mathbf{I}_{mod})$ ：

$$\mathbf{L}^{(i)}(\mathbf{I}_{mod}) = \|\psi_{\mathbf{I}_{mod}}(p \pm 68) - \psi_{\mathbf{I}_{mod}}(q \pm 68)\|_2^2 \quad (3.2)$$

其中 i 指定的关键点组数， p, q 指一个关键点组中任意两点， n 为关键点的个数，数量为 68 的倍数。选择相对距离 $\mathbf{L}^{(i)}(\mathbf{I}_{mod})$ 最大的一组关键点来确定视频帧中主要人脸。如图 12 所示，1 框内为目标人脸，2 框为错误识别。通过上述算法在实验过程中错误标定率明显下降。

3.2.2 局部加权平均算法

对每段视频的第一帧 $\mathbf{I}_{j,1}$ 应用 ASM 算法标定 68 个人脸关键点 $\psi(\mathbf{I}_{j,1})$ ，使用局部加权平均函数（Local Weighted Mean, LWM）建立模型脸关键点集 $\psi(\mathbf{I}_{mod})$ 与视频第一帧关键点集 $\psi(\mathbf{I}_{j,1})$ 之间的对应关系^[78]：

$$\mathbf{T}_j = LWM(\psi(\mathbf{I}_{mod}), \psi(\mathbf{I}_{j,1})), \quad j = 1, \dots, l \quad (3.3)$$



图 12 ASM 算法标定的 68 个人脸关键点

其中 j 是视频段号, l 是视频片段总数。对视频片段的所有帧应用该关系, 使视频的每一帧具有与模型脸 $\psi(I_{mod})$ 统一的姿态:

$$I'_{j,k} = T_j \times I_{j,k}, \quad k = 1, \dots, n_j \quad (3.4)$$

其中 $I_{j,k}$ 为第 j 个视频片段的第 k 帧, $I'_{j,k}$ 为统一姿态后的第 j 个视频片段的第 k 帧, n_j 为 j 视频片段的帧数。如图 13 所示, 两图均按照模型脸统一姿态, 左图剔除了错误识别, 右图改变了头部的倾斜角度, 实验表明通过这种方法大大减少了非表情因素的干扰。

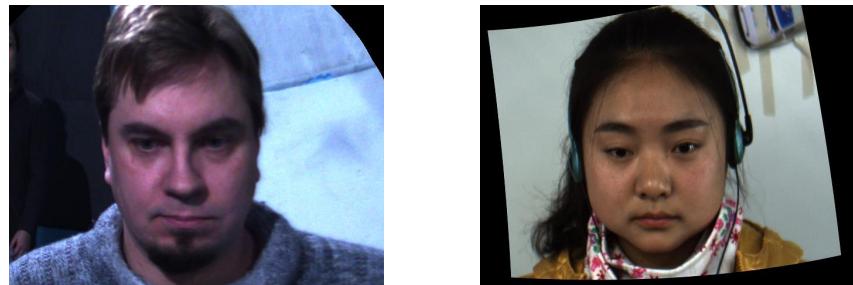


图 13 LWM 算法人脸对齐后的图像

3.2.3 时间插值模型

微表情识别其中一个特殊的挑战是微表情持续时间短。例如, SMIC 数据集中最短的片段持续时间为 $3/25$ 秒, 只有 3 帧 (25 fps) 之多。这样的短序列严重限制了许多时空特征描述符的应用, 如 LBP-TOP 特征沿时间维度的可行半径 r 只能为 1。除此之外, 微表情视频片段之间有不同的长度, 而且变化也相当大, 从 4 帧到 50 帧 (如果用 100 帧/秒的相机拍摄) 不等, 这也对一些对视频帧数敏感的特征描述符提出了挑战。

Zhou 等人在论文 [79] 中提出了一种时间插值模型 (Temporal Interpolation Model, TIM)。该模型在原论文中用于唇语识别 (Lipreading), 论文中提到如果我们将一段视频中讲话嘴的运动视为连续过程, 则语音视频的图像序列可以被视为沿着表示图像空间中话语的曲线以固定速度采样的一组图像, 或更一般地表示为从图像中提取的视觉

特征。通常，这样的空间具有高维度，并且我们可以假定存在一个低维流行，其中连续的发声过程可以通过连续和某种确定性函数来表征。根据这样的特性，我们将其一般化地应用到低分辨率环境下微表情识别的框架中，使用 TIM 方法来解决与微表情持续时间和帧数差异相关的问题。在我们的工作中，我们通过将输入视频表示为路径图 P_n 来揭示这样的功能，其中 n 是顶点数。图 14 (a) 给出了这种图表示例，如图所示，每个顶点对应于一个帧，并且顶点之间的连接可以由邻接矩阵 $\mathbf{W} \in \{0,1\}^{n \times n}$ 表示，其中当 $|i - j| = 1, i, j = 1, 2, \dots, n$ 时 $W_{ij} = 1$ ，否则为 0。

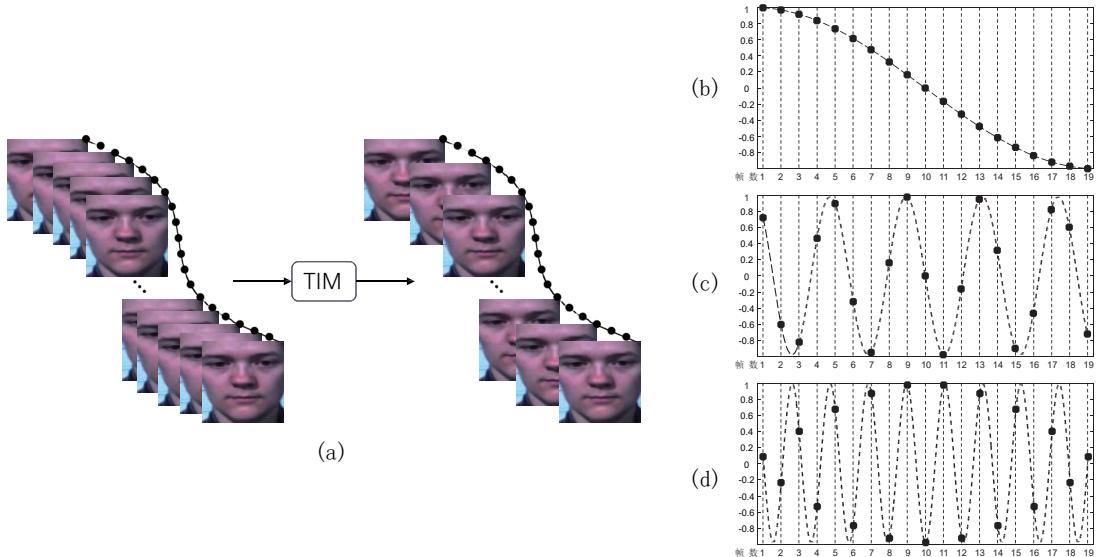


图 14 TIM 方法映射过程

- (a) 共 19 帧的图像序列插值过程 (P_{19})，输入为原始图像，输出为插值后图像；
- (b) - (d) 为图像序列的 Laplacian 第 1、第 9 和第 18 特征向量的映射。

在本文中对由重建出的高分辨率图像组成的图像序列应用 TIM 算法统一帧数：将重建的图像序列映射到一条非线性曲线上 $\mathcal{F}^n : [1/n, 1] \rightarrow \mathbb{R}^{n-1}$ ，

$$\mathcal{F}^n(t) = \begin{bmatrix} f_1^n(t) \\ f_2^n(t) \\ \vdots \\ f_{n-1}^n(t) \end{bmatrix} \quad (3.5)$$

其中 $f_k^n(t) = \sin(\pi kt + \pi(n-k)/n)$, $t \in [1/n, 1]$ ， n 为视频段中帧数（图像序列个数），根据实验需求等间距采样，获得统一帧数。

TIM 方法通过路径图来描述帧序列的结构：学习图像序列特定的映射以连接图像序列中的帧和嵌入在路径图中的曲线，从而将图像序列投影到路径图中，如图 14 (a) 所示。图 14 (b) - (d) 的曲线是 $[0,1]$ 区间内单个变量 t 的连续确定性函数，控制着帧间

的时间关系。在微表情的连续过程中出现的不可见的帧也可以用曲线来表征。因此，使用 TIM 方法，无论是向下采样还是向上采样，通过控制变量 t 在不同时间点的变化，我们都将帧序列改变为任意长度。

在本文提出的框架中，TIM 方法被用来将所有的微表情片段（数据集）插为一个固定的长度，例如，10 帧、20 帧或 40 帧。这样既可以解决持续时间短的问题，也可以解决序列长度不统一的问题。当前步骤的目的方面可以在选择特征参数时提供更多的选项，另一方面利用时空特征描述符实现更稳定的性能。如何选择最合适的 TIM 插值长度的问题在论文 [13] 中进行了探讨和讨论，本文将其讨论结果作为参考，具体如章节3.5的实验部分所述。

3.3 超分辨重建过程

在本文中，我们分别提出了基于块和基于像素的两种新的正则化，它们可以有效地将输入的低分辨率人脸图像重建成高分辨率人脸图像。与依赖于低分辨率和高分辨率空间中局部几何一致性假设的传统基于块的模型不同，所提出的方法直接规范了目标块与高分辨率空间中相应训练集之间的关系。它避免了处理在不同分辨率下保留局部几何结构的棘手问题。利用核函数有效地描述内在特征，我们在高维核空间进一步进行基于块的模型重建，以捕获非线性特征。同时，提出了一种基于像素的模型来规范局部邻域中像素的关系，可以用来增强目标高分辨率人脸图像中的模糊细节。它主要是沿着结构的主导方向重建像素，这对于保留复杂边缘上的高频信息是有用的。最后，我们将两个重建模型组合成一个统一的框架。可以通过执行迭代过程来最终优化输出重建的高分辨率人脸图像。实验结果表明，所提出的人脸 Hallucination 方法比现有技术方法具有更好的性能。

重建模型 $\mathbf{L} = \mathbf{DBH} + \varepsilon$ 中的高分辨率人脸图像 \mathbf{H} 严重欠定，意味着每个低分辨率人脸图像对应于无限多个高分辨率估计。为了改善这个问题，必须在整个重建过程之前加入进一步的正则化。通过附加先验条件，可以获得高分辨率人脸图像 \mathbf{H} 的唯一解决方案。重建模型可以表示为：

$$\mathbf{H} = \arg \min_{\mathbf{H}} \left\{ \|\mathbf{L} - \mathbf{DBH}\|_2^2 + \gamma R(\mathbf{H}) \right\} \quad (3.6)$$

其中 $R(\mathbf{H})$ 表示正则化模型， γ 是平衡重建误差和正则化项的相应参数。在4.1中，第一项确保了估计的高分辨率人脸图像和观察到的低分辨率人脸图像的一致性，而附加的先验项进一步规范了高分辨率人脸图像的局部细节。根据人脸图像的特点，提出了两种有

效的正则化模型，以约束重建过程。以下将描述上述两个先验项的细节。

低分辨率图像和高分辨率图像在质量和分辨率上都是不同的。高分辨率图像序列的微表情识别方法不能直接应用于低分辨率图像序列。在 2.1 节中，我们介绍了从高分辨率图像生成低分辨率图像的过程。

为了重建高分辨率图像，论文 [76] 提出了一种新的人脸幻觉算法。将基于块的正则化项与基于像素的正则化项相结合，对目标函数进行约束。重构后的高分辨率图像 \mathbf{H} 可以通过最小化以下目标函数得到：

$$f(\mathbf{H}) = \|\mathbf{L} - \mathbf{DBH}\|_2^2 + \alpha \mathbf{F}_{patch} + \eta \mathbf{F}_{pixel} + \lambda \mathbf{F}_{penalty} \quad (3.7)$$

其中右侧第一项为重建误差，后三项分别是基于块的正则项、基于像素的正则项以及惩罚项。图 15 展现了重建工作的具体流程。具体将在下文详细介绍。

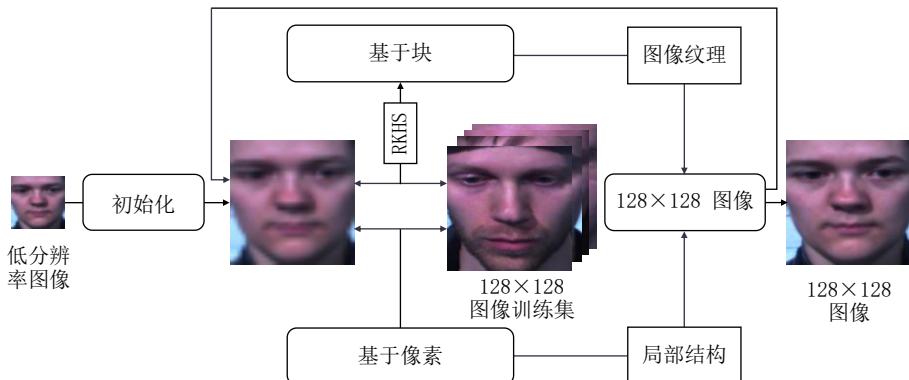


图 15 超分辨重建过程

3.3.1 基于的块方法

将分割后的图像 \mathbf{L} （低分辨率图像）应用三线性插值法调整为与训练样本图像 \mathbf{H} （高分辨率图像，来自公开的高分辨率图像集）大小相等的尺寸，将此图命为 $\mathbf{H}^{(0)}$ （超分辨重建过程的初始图像），对图像分块处理（如分块数为 8×8 ），如图 7 所示，最小化代价函数：

$$\begin{aligned} J_\tau(\omega_\tau, \mathbf{H}^{(k)}) &= \left\{ \|\phi(\mathbf{R}_\tau \mathbf{H}^k) - \phi(\mathbf{H}_\tau) \omega_\tau\|_2^2 + \lambda \left\| \mathbf{d}_\tau \bigotimes \omega_\tau \right\|_2^2 \right\} \\ s.t. \mathbf{1}^T \omega_\tau &= 1, 2, \dots, M \end{aligned} \quad (3.8)$$

估算结合系数 ω_τ ，将其初始结合系数命名为 ω_τ^0 ，此时 $\mathbf{H}^{(k)}$ 已知，即 $\mathbf{H}^{(0)}$ ，其中 τ 为图像中图像块的位置， \mathbf{R}_τ 为提取所有图像集位置 τ 的图像块的矩阵， $\mathbf{H}_\tau = [h_\tau^1, \dots, h_\tau^N]$ 为高分辨率图像位置 τ 处图像块集 (N 为训练样本的数量，即高分辨率图像集的数量)， $\phi(\cdot)$

为从原始空间到无限维再生核希尔伯特空间 (Reproducing Kernel Hilbert Space, RKHS) 的映射, \mathbf{d}_p 描述了目标高分辨率块 (重建出的块) 与相应的训练样本块在核映射空间的核相似性, \otimes 表示哈达玛积, λ 为惩罚系数, $\mathbf{1}$ 为全为 1 的列向量, M 为图像的块数。

3.3.2 基于像素的方法

可以通过解决上述优化问题 (25) 来获得最终的高分辨率人脸图像 \mathbf{H} 。但是, 目标函数是非凸优化问题, 很难直接获得全局最优解。幸运的是, 我们可以期望通过迭代过程获得局部最优解。为了解决 (25) 中的问题, 我们可以分别优化 ω_τ 和 \mathbf{H} , 同时固定另一个值。例如, 如果 ω_τ 的值是固定的, 则可以通过最小化以下函数来获得最优 \mathbf{H} :

$$\begin{aligned} f(\mathbf{H}) = & \|\mathbf{L}^k - \mathbf{DBH}^k\|_2^2 + \eta \sum_{\tau} \|x_\tau \mathbf{h}^k - \beta_\tau \mathbf{H}_\tau\|_2^2 + \\ & \alpha \sum_{\tau} (\|\phi(\mathbf{R}_\tau \mathbf{H}^k) - \phi(\mathbf{H}_\tau) \omega_\tau\|_2^2 + \lambda \|\mathbf{d}_\tau \otimes \omega_\tau\|_2^2) + \sigma \mathbf{MSE} \quad (3.9) \end{aligned}$$

s.t. $\mathbf{1}^T \omega_\tau = 1, 2, \dots, M$

获得重建的高分辨率图像 $\mathbf{H}^{(k)}$ (初始结果命名为 $\mathbf{H}^{(1)}$), 其中 \mathbf{D} 为下采样矩阵, \mathbf{B} 为模糊处理矩阵, β_τ 为规范全局优化的像素间关系矩阵, \mathbf{MSE} 为均方误差, η 为基于像素的正则项系数, α 为基于块的正则项系数, σ 为均方误差的系数。

基于块的模型可以恢复人脸图像的大多数高频纹理。然而, 局部结构需要进一步考虑抑制复杂边缘上的伪像。其目的在于表征相邻像素之间的关系以增强边缘结构, 这在基于块的先验项中未被考虑。

通过交替优化公式 4.4 和公式 4.3 来解决目标函数。因此, 它需要对两个目标函数进行初始估计, 以便开始迭代。我们首先利用低分辨率图像特征来代替公式 4.3 中高分辨率空间的相应特征, 这给出了对 ω_τ 初始值的粗略估计。在初始化之前, 通过双三次插值将低分辨率图像放大到与高分辨率相同的大小, 以获得更多的高频信息。我们还简单地将低分辨率 \mathbf{L} 的插值结果视为高分辨率人脸图像 $\mathbf{H}^{(0)}$ 的初始估计。

利用两个目标的初始值, 我们可以通过最小化公式 4.4 来优化输出高分辨率图像 \mathbf{H} 。一旦完成, 通过求解公式 4.3 获得每个位置的组合系数 ω_τ 。我们重复迭代过程以更新上述目标, 直到优化问题 (25) 收敛到局部最小值。最后, 获得最优解 \mathbf{H} 作为输出高分辨率人脸图像。算法 1 总结了完整面部幻觉程序的细节。

在本文中, 我们提出了两种新的正则化模型来处理低分辨率人脸模糊问题。基于块的模型规范了高分辨率空间中目标块和训练块之间的关系, 这有效地恢复了局部纹理。与以前在低分辨率空间中建立正则化的方法不同, 它避免了保持局部几何一致性的困

难。此外，高分辨率块片被投射到 RKHS 中，这有助于寻求重建中的非线性关系。基于像素的模型被设计用于补偿局部细节，尤其是眼睛、鼻孔和嘴部区域。它沿着结构的主导方向对像素进行重建，这对于重建局部边缘结构是有效的。通过组合上述两种正则化模型，可以最终优化整个高分辨率图像。实验结果表明，与各种条件下的现有基线相比，所提出的方法产生了优异的结果。

3.4 微表情的特征提取与分类

如章节二所述，时空描述符是微表情分析研究的主流。如图 10 所示，微表情识别主要分为两部分：特征提取和分类。本文提出的微表情识别框架使用 LBP-TOP 时空特征和线性支持向量机分类器。

在以往的微表达分析方法中研究人员展示了 LBP-TOP 及其变体作为特征描述符的优势。与传统的基于单个图像的 LBP 特征不同，LBP-TOP 可以捕捉到空间和时间域的动态变化，这对于微表情识别是必不可少的。在分类部分，我们使用 LSVM 作为分类器。为了进行公平的比较，我们在实验中采用了 Leave-one-subject-out 协议。

3.4.1 LBP-TOP 特征提取

LBP-TOP 由 Zhao & Pietikäinen 在论文 [59] 中提出。LBP-TOP 是原 LBP 的扩展，用于时空域的动态纹理分析。根据章节二的相关工作中的描述，LBP-TOP 及其变体是目前微表情识别研究中最常用的特征。

视频序列可以看作是 X、Y 和 T 维上像素的长方体，传统的 LBP 代码可以从 XY、XT 或 YT 平面上提取特征直方图，如图 16 中 LBP-TOP¹ 所示（图中的红色立方体）。为了总结三维长方体的时空属性，将每个平面的三个 LBP 直方图拼接成一个大直方图作为最终的 LBP-TOP 特征向量，如图 16 中 LBP-TOP² 所示，关于 Blocksize 的划分将在章节三中讨论。

按照这种方法我们首先将整个人脸图像序列划分为几个长方体，如 $5 \times 5 \times 1$, $8 \times 8 \times 2$ 等，其中前两个参数决定了空间域中的块数，最后一个参数是时间方向上的块数。每个长方体都可以看作一个新的单元，从新单元中三个不同的正交平面 (XOY、XOT、YOT) 提取 LBP 特征，我们遍历所有长方体，得到图像序列的 LBP-TOP 特征，然后将每个长方体的 LBP-TOP 特征串联起来。

3.4.2 线性支持向量机及交叉验证

支持向量机 (Support Vector Machine, SVM) 是一类按监督学习方式对数据进行分类的广义线性分类器，它在解决小样本、非线性及高维模式中有许多特有的优势。SVM 的关键在于核函数，采用不同的核函数就会有不同的 SVM 分类结果。常用到的核函数有

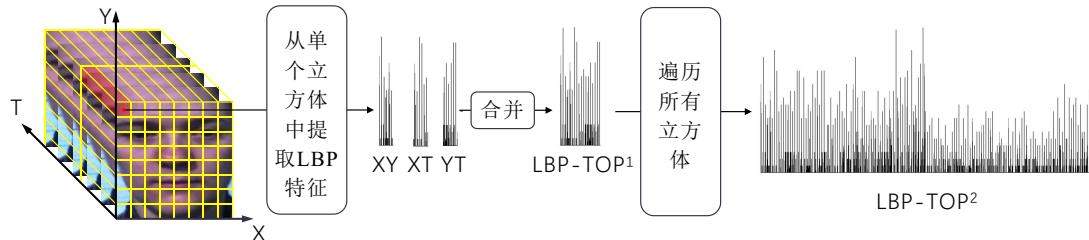


图 16 LBP-TOP 特征提取过程

线性核 (Linear Kernel)、卡方核 (Chi-square Kernel)、直方图交叉核 (Histogram Intersection kernel)。SVM 从 90 年代后期开始在很多领域均有举足轻重的应用，是曾经打败神经网络的分类方法，近年来，由于深度学习的兴起，SVM 的风光开始衰退，但是其仍然不失为一种经典的分类方法。

虽然分类器的选择也很重要，但它并不是目前研究的主要目的。为了保持良好的控制，并将更多的注意力放在框架的前几个步骤上，在接下来的微表情识别实验中，我们使用了线性支持向量机 (Linear Support Vector Machine, LSVM) 作为分类器^[80]，使用 leave-one-subject-out 协议进行验证。根据数据集发布方提供的微表情表签，我们将来自 SMIC 的样本分为三类 (Positive、Negative、Surprise)，来自 CASME II 的样本分为五类 (Happiness、Surprise、Repression、Disgust、Other)。下面将简单描述它们的细节，并将在章节3.5中提供最终的实验数据。

交叉验证是用来验证分类器性能的一种统计分析方法。其基本思想是将样本数据集分成两个子集，一个子集用于训练分类器称为训练集，另一个子集用于验证分析分类器的有效性称为测试集。其利用测试集来测试训练得到的分类器，以此作为分类器的性能指标。常用的方法有简单交叉验证、K 折交叉验证和 leave-one-subject-out (LOSO) 交叉验证。LOSO 交叉验证方法每次选择一位受试者的所有视频序列作为测试样本，其余 n 个受试者的所有视频序列作为训练样本，重复 $n + 1$ 次实验，计算 $n + 1$ 次的平均分类识别率。所以 LOSO 交叉验证方法的样本利用率最高，适合小样本的分类计算。故运用 LOSO 交叉验证方法对不同核函数的 SVM 分类器进行微表情的分类实验可以得到更为准确的结果。

3.5 实验设置及分析

该框架在 SMIC 和 CASMEII 两个数据库上进行了测试。为了探究框架中每个单独步骤的效果，我们针对不同的目的分别进行了四个子实验。子实验及其结果如下所述。

TIM 插值的效果

在第一个子实验中，我们想要评估插值过程将如何影响框架的性能。我们也希望找

到一个合适的序列长度（或长度范围），这将有效的提升微表情识别任务。

原始微表情片段的平均序列长度：SMIC-HS 为 33.7 帧，SMIC-VIS 为 9.66 帧，SMIC-NIR 为 9.66 帧。为了避免其他因素的影响，将重点放在 TIM 过程上，我们跳过了运动放大的步骤，只使用 LBP-TOP（参数固定为 $8 \times 8 \times 1$ 个 block, $r = 2$, $p = 8$ ）作为特征描述符。在 TIM 步骤中我们选择 8 个插值长度（10、20、…），对 SMIC-HS、SMIC-VIS 和 SMIC-NIR 数据集的框架进行评估。

测试结果如图 6 所示。研究结果可以归纳为两个方面。首先，插值到 10 帧（简称 TIM10）比不使用 TIM 过程的性能要好得多。与原始序列相比，TIM10 几乎没有改变 SMIC-VIS 和 SMIC-NIR 的平均序列长度，但是 SMIC-HS 的下采样过程。因此，我们认为序列长度的统一导致了性能的提高。其次，如果我们将 TIM10 的结果与较长的 TIM 序列的结果进行比较，就会发现较长的插值序列并不会带来更好的性能。对这个结果的一种可能的解释是，如果微表情片段被插值成更长的序列，时间维度的变化就会被稀释。根据这两个发现，对于目前的框架来说，TIM 为 10 帧似乎是最好的选择。在接下来的所有实验中，如果没有另外指定，TIM10 将作为默认值应用于框架中。

特征的比较

第二个子实验的目的是比较三个特征的性能。在每个特征的三个正交平面上分别计算五种直方图组合。

人脸对齐后，应用 TIM10 对所有序列进行 10 帧插值。在后面的讨论中暂时跳过了运动放大步骤。从不同参数序列的均匀分割块中提取三种特征。对于 LBP 特征，我们改变半径 r ，邻点 p 和划分块数；对于 HOG 和 HIGO 特性，我们将 bin 的数量固定为 $b = 8$ ，并改变划分块的数量。对 SMIC 和 CASMEII 的三个数据集进行了测试，结果如表 5 所示。注意，每个特征的三个正交平面的五个组合的结果被单独列出。对于每个特征组合（表中的一个单元格），只列出所有参数组合中获得的最佳结果（具有相应的参数）。

从结果表中可以发现两个现象。首先，最上面的组合（三个正交平面）并不总是带来最好的性能，特别是对于 HIGO 特性。在许多情况下，仅使用 XOT、YOT 或 XYOT 计划特性就可以获得更好的结果，对于所有四个数据集都是如此。另一方面，XY 平面特征总是比其他平面组合得到最低的性能。结果表明，T 维上的动态变化是微表情识别中最重要的信息，而 XY 平面特征所携带的面部特征信息更多，这可能是微表情识别任务中多余的信息，Davison 等人也提出了类似的发现。其次，比较这三种特征，基于梯度的特征 HOG 和 HIGO 在四个测试数据集中的三个（SMIC-NIR 除外）上优于 LBP。HIGO 的性能似乎略优于 HOG，在 SMIC 上使用 HIGO-XOT 获得的最高性能为 76.06%。一种

可能的解释是 HIGO 特征不受局部梯度大小的影响，局部梯度大小可能由于微表情片段中肌肉运动速度的多样性而变化。近红外数据显示了另一种趋势。近红外相机记录的皮肤纹理不同于可视彩色视频。对于 SMIC-NIR 数据集，LBP 特征优于其他两个特征，这与 Zhao 等（2011）之前的研究结果一致。

表 4 实验中使用的数据集

	SMIC-HS	SMIC-subHS	CASME II
微表情数	164	71	247
参与者	16	8	26
分类	3	3	5

我们现在在三个不同的自发微表达数据集上展示实验和结果，即 SMIC-HS, SMIC-subHS 和 CASME II。实验参数的设置和结果分析将在下面的小节中讨论。

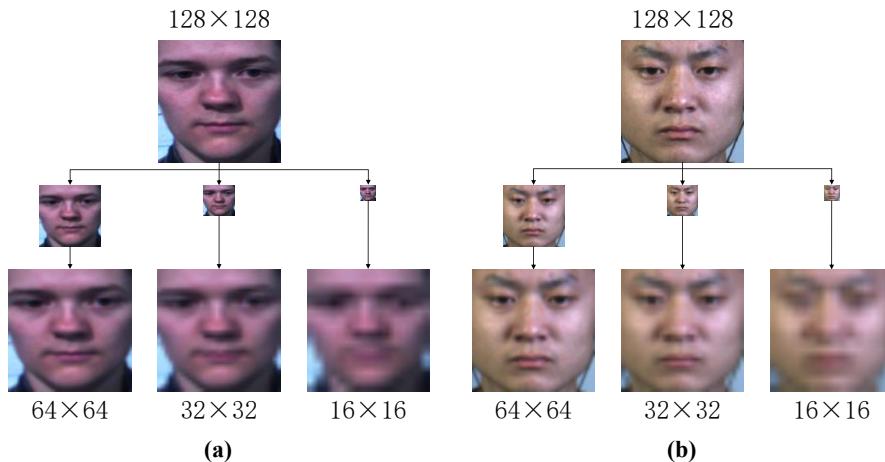


图 17 低分辨率图像

(a) SMIC-HS/SMIC-subHS 数据集低分辨率图像, (b) CASME II 数据集低分辨率图像

SMIC-HS 和 SMIC-subHS 是 SMIC 的两个子集。SMIC-HS 数据集包含来自 16 名参与者的 164 个自发微表情片段，分为三类：积极（51 个片段）、消极（70 个片段）和惊讶（43 个片段）。SMIC-subHS 数据集是 SMIC-HS 的子集，只包含最后 8 个参与者。前 8 名受试者的微表达片段数量差异较大，其中 3 名受试者贡献了整个组近一半的微表达样本，这可能会影响“一受试者退出”的表现，而后 8 名受试者的（SMIC-subHS）片段数量分布较为均匀。SMIC-subHS 数据集中，正负、惊喜片段分别为 28、23、20 个。同时，CASME II 数据集包含 26 名参与者，分别属于 5 个不同的类别：惊讶（25 个片段）、快乐（32 个片段）、其他（99 个片段）、厌恶（64 个片段）和压抑（27 个片段）。表 1 显示了实验中使用的数据集的摘要。面部高分辨率图像的分辨率设置为 128×128 的实验。 128×128 分辨率的图像下采样乘以 2,4,8 次获得低分辨率图像（如图 6）。这意味着我们

评估三个不同层次的低分辨率的面部图像序列（如 16×16 , 32×32 , 64×64 ）的微识别任务。

在本节中，利用论文 [76] 提出的方法将低分辨率图像重建为高分辨率图像，该方法在 2.3 节中进行了简要介绍。表 2-3 列出了不同分辨率下重建图像序列的平均峰值信噪比（PSNR）和结构相似度（SSIM）指数。在这里，我们分别使用 S64、S32 和 S16 来命名分辨率为 64×64 , 32×32 和 16×16 的重建图像序列。

表 5 重建图像序列的平均 PSNR (dB) 指标

PSNR (dB)	16×16	32×32	64×64
SMIC-HS	31.25	37.67	44.30
SMIC-subHS	31.67	38.26	43.22
CASME II	31.80	36.49	37.83

表 6 重建图像序列的平均 SSIM 指标

SSIM	16×16	32×32	64×64
SMIC-HS	0.9397	0.9775	0.9883
SMIC-subHS	0.8970	0.9346	0.9424
CASME II	0.9439	0.9761	0.9882

如表 2 和表 3 所示，重建的人脸图像序列的定量指标（PSNR/SSIM）与输入人脸图像序列的分辨率成正比。例如，在 SMIC-HS 数据集中，S16 的 PSNR 指数为 31.25dB，比 S32 低 6.42dB，比 S64 低 13.05dB。对于 SSIM 指数，S16 达到 0.9397，比 S32 低 0.0378，比 S64 低 0.0486。此外，图 7 给出了重建后的图像序列的视觉表现，也表明了与上述观点相同的结论。

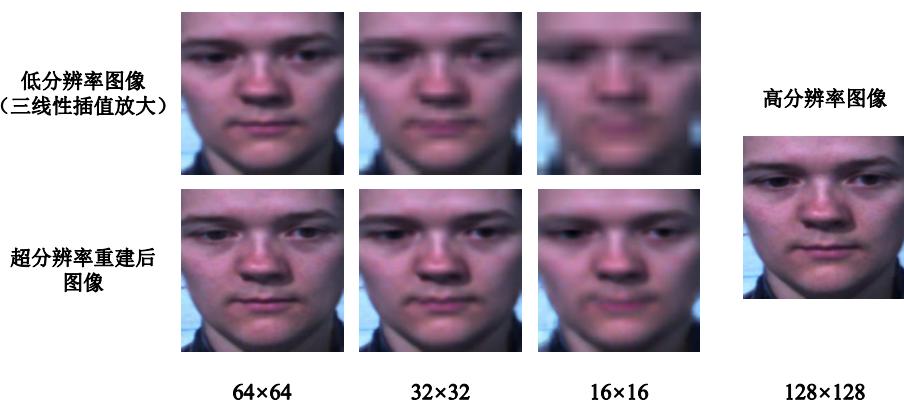


图 18 不同分辨率图像重建结果比较

为了对视频片段的时长进行归一化，使用 TIM 算法将视频片段的帧数插值为 10 帧，

如 2.2 节所述。我们应用快速 LBP-TOP 将视频片段成不同的长方体和提取每个长方体的 LBP-TOP 特征构成一个完整的功能, 使用统一的映射, 半径设置为 $r = 2$, 和相邻点 p 的数量设置为 $p = 8$ 。我们使用 leave-one-subject-out 协议进行实验, 即, 将一个受试者的所有样本作为测试集, 其他受试者的所有样本作为训练集。我们采用 LSVM 作为分类器, 其中惩罚系数 $c = 1$ 。

在本节中, 我们提出了低分辨率图像序列的微表情识别性能的基线。为了适应不同分辨率的测试样本, 我们将训练集从 128×128 下采样到对应的分辨率 (即), 以便进行分类程序。注意, 下采样操作导致微表达式缺乏判别特征。接下来的实验也表明, 在非常低的分辨率下, 识别的准确率会急剧下降。

图 8 显示了不同分辨率图像序列在不同数据集上的识别精度。在这里, 我们分别使用 L64、L32 和 L16 来命名低分辨率图像序列。从图 8 可以看出, 当输入图像序列的分辨率从 64×64 降低到 32×32 时, SMIC-SubHS 数据集 (蓝色折线) 的识别准确率显著降低。同时, 我们可以看到低分辨率图像序列 (如 L16) 的准确率相对较低。这一现象表明, 低分辨率的图像序列很难获得满意的结果。主要原因是低分辨率导致微表情描述缺乏高频信息和纹理细节。

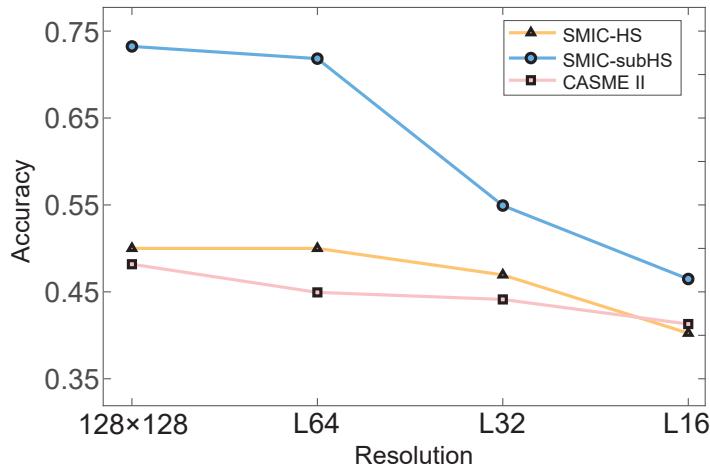


图 19 不同数据集不同分辨率的图像序列的识别准确度

图 9 为低分辨率图像序列分类结果的混淆矩阵, 并以 128×128 分辨率下的性能为参考。我们可以发现, 在 SMICSubHS 数据集 (图 9 第二列) 中, 当图像序列的分辨率为 128×128 时, 混淆矩阵更加集中在对角线上, 说明微表情识别方法的识别效果较好。然而, 当图像序列的分辨率降低时, 混淆矩阵逐渐变差。我们还可以发现, 在 SMICHs (图 9 第一列) 和 CASME II (图 9 第三列) 中, 误分类的比例大于 SMICsubHS, 图 8 所示的识别准确率也相对较低。对于 SMIC-HS 来说, 上述问题的主要原因可能是后 8 个受试者 (SMIC-subHS 数据集) 的分布比前 8 个受试者更加均衡。对于 CASME II 来说,

主要是由于分布不平衡和类别过多。例如，在 CASME II 数据集中，来自类 other 的视频片段数量占 40.08%。

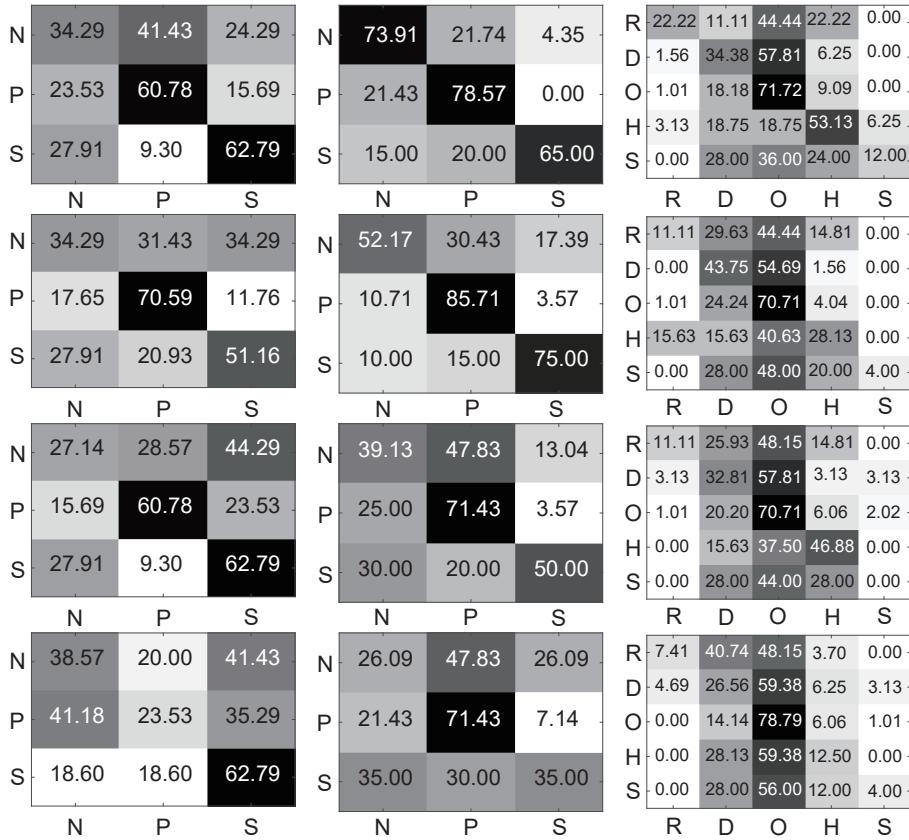


图 20 不同分辨率图像序列的识别准确度混淆矩阵

水平方向，从左往右依次是 SMIC-HS 数据集、SMIC-subHS 数据集和 CASME II 数据集。垂直方向，从上到下依次是 128×128 分辨率混淆矩阵、 64×64 分辨率混淆矩阵、 32×32 分辨率混淆矩阵和 16×16 。其中 P 代表积极 (Positive)、N 代表消极 (Negative)、S 代表惊讶 (Surprise)、R 代表压抑 (Repression)、D 代表厌恶 (Disgust)、O 代表其他 (Others)、H 代表快乐 (Happiness)。

在本小节中，我们将在三个数据集上对我们提出的框架进行实验。首先将测试集重构为 128×128 的分辨率，然后在高分辨率空间中进行分类。通过实证分析，选择了最优参数。表 4 给出了识别精度以及相应的块大小参数设置。从表 4 可以看出，实验结果有了显著的改善。例如在 SMIC-subHS 数据集中， 64×64 分辨率下的图像序列识别准确率从 71.83% 提高到 74.65%，提高了 2.82%。S32 的识别准确率为 74.65%，比 L32 高 19.72%。S16 的识别准确率为 73.24%，比 L16 高 26.76%。这表明该方法对低分辨率图像序列的微表情识别精度有较好的提高。我们还注意到，与直接将输入作为原始的 128128 个图像序列相比，该框架使用 S64 得到了更好的结果。这可能是因为原始 SMIC-HS/subHS 数据集中的样本在记录过程中存在明显的噪声，使得人脸序列实际上包含了冗余和噪声

信息。

超分辨率重建图像序列识别精度的混淆矩阵如图 17 所示。我们展示了 128×128 、 $S64$ 、 $S32$ 和 $S16$ 图像序列根据不同数据集的识别精度。从图 17 可以看出，我们提出的框架的混淆矩阵比图 9 更集中在对角线上。特别是在 16×16 SMIC-HS 数据集（左下），积极的识别精度有显著提高。此外，我们可以从 SMIC-subHS 数据集（第二列）的结果中看出，将阴性误分类为阳性的比例显著降低，而将阳性正确分类的比例也得到了大幅提高。不幸的是，尽管 CASME II 数据集（第三列）的结果有所改善，但每个类别的分类仍然很差，通常错误地划分为其他类别。也许是因为其他微表情包含了所有其他类型的微表情，不包括惊讶、快乐、厌恶和压抑，所以它的分类是混合的。综上所述，从图 17 和图 9 的对比中我们可以看出，该框架对于低分辨率的微表情识别具有很好的性能提升。

表 7 不同分辨率图像在不同数据集上的识别精度比较

Accuracy (%)	High-resolution	Super-resolution Reconstruction			Low-resolution		
		128×128	64×64	32×32	16×16	64×64	32×32
SMIC-HS	50.00 ($8 \times 8 \times 2$)	52.44 ($5 \times 5 \times 2$)	51.83 ($5 \times 5 \times 2$)	51.83 ($5 \times 5 \times 2$)	50.00 ($6 \times 6 \times 5$)	46.95 ($6 \times 6 \times 5$)	40.24 ($3 \times 3 \times 6$)
	73.24 ($5 \times 5 \times 2$)	74.65 ($5 \times 5 \times 2$)	74.65 ($5 \times 5 \times 2$)	73.24 ($8 \times 8 \times 3$)	71.83 ($6 \times 6 \times 2$)	54.93 ($6 \times 6 \times 2$)	46.48 ($4 \times 4 \times 1$)
CASME II	48.18 ($7 \times 7 \times 3$)	48.18 ($7 \times 7 \times 5$)	44.53 ($7 \times 7 \times 3$)	42.92 ($7 \times 7 \times 5$)	44.94 ($7 \times 7 \times 1$)	44.13 ($4 \times 4 \times 2$)	41.30 ($2 \times 2 \times 5$)

High-resolution 是指分辨率为 128×128 的图像序列，**Super-resolution Reconstruction** 是指将低分辨率图像序列通过超分辨率重建方法为 128×128 ，**Low-resolution** 是指重建前的低分辨率图像序列。 $X \times Y \times T$ 指水平、垂直和时间方向块的数量。

3.6 本章小结

本文对低分辨率微表情识别问题进行了全面的研究。我们使用模糊和下采样模型来生成和模拟低分辨率的微表情人脸图像序列。我们在每一帧上使用面部幻觉的方法重建高质量的面部图像序列，增强局部细节，将低质量的图像序列放大到高分辨率的图像序列。然后利用快速 LBP-TOP 提取动态特征，利用 SVM 分类器对微表情进行识别。实验结果表明，在低分辨率的微表情识别问题上，该框架在可公开获取的微表情数据集（SMIC-HS、SMIC-subHS、CASME II）上表现良好。

第四章 基于深度学习方法的低分辨率环境下微表情识别

我们考虑在不受控制的环境中对动作的全自动识别。大多数现有的工作依赖领域知识从输入构建复杂的手工特性。此外，通常假定环境是受控的。卷积神经网络（Convolutional Neural Networks, CNN）是一种深度模型，它可以直接作用于原始输入，从而实现特征构造过程的自动化。然而，这些模型目前仅限于处理 2D 输入。在本文中，我们开发了一种新的三维 CNN 动作识别模型。该模型通过三维卷积从空间和时间两个维度提取特征，从而获取多个相邻帧中编码的运动信息。所建立的模型从输入帧中生成多个通道的信息，并结合所有通道的信息得到最终的特征表示。我们将开发的模型应用到现实环境中的人类行为识别中，在不依赖于手工制作的特性的情况下取得了优异的性能。

微表情是检测谎言的重要线索之一。它最突出的特点是运动时间短、强度低。因此，高时空分辨率的视频片段比静止图像更需要提供足够的细节。另一方面，由于微表达数据的采集和编码困难，样本量较小。在本文中，我们仅使用 560 个微表情视频片段来评价所提出的转移长期卷积神经网络（Transfer Long-term Convolutional Neural Network, TLCNN）。TLCNN 利用深度 CNN 从微表情视频片段的每一帧中提取特征，然后将其输入到长短期记忆网络（Long Short-Term Memory, LSTM）中，LSTM 学习微表情的时序信息。由于微表情数据的样本容量较小，TLCNN 采用了两个迁移学习的步骤：(1) 从表情数据进行迁移，(2) 从单帧微表情视频片段进行迁移，可视为“大数据”。对采集自三个自发性数据库的 560 个微表情视频片段进行评价。结果表明，所提出的 TLCNN 算法优于现有的一些算法。

近年来，随着计算机硬件特别是图形处理器（Graphics Processing Unit, GPU）的飞速发展，深度学习在人脸识别、验证等领域得到了广泛的应用，表现出了优异的性能。这些深度学习方法使用多个处理层来发现非常大的数据集中的模式和结构。每一层从后续层构建的数据中学习一个概念；层次越高，所学的概念就越抽象。深度学习不依赖于先验数据处理，自动提取特征。这些优势和深度学习的良好表现都归功于大数据。然而，微表情视频片段的数量通常很少。在样本容量较小的数据上进行深度学习可能不会取得良好的效果。针对这一问题，我们利用转移学习对深度卷积神经网络进行预处理，提出了用于微表情识别的 TLCNN 网络。在 TLCNN 中，迁移学习有两个步骤：(1) 从表情数据进行迁移，(2) 从单个微表达视频片段帧进行迁移，这可以看作是大数据。为了充分利用微表情视频中的时间信息，TLCNN 还利用 LSTM 从每帧图像的中层图像表

示中提取微表情视频的时间特征。

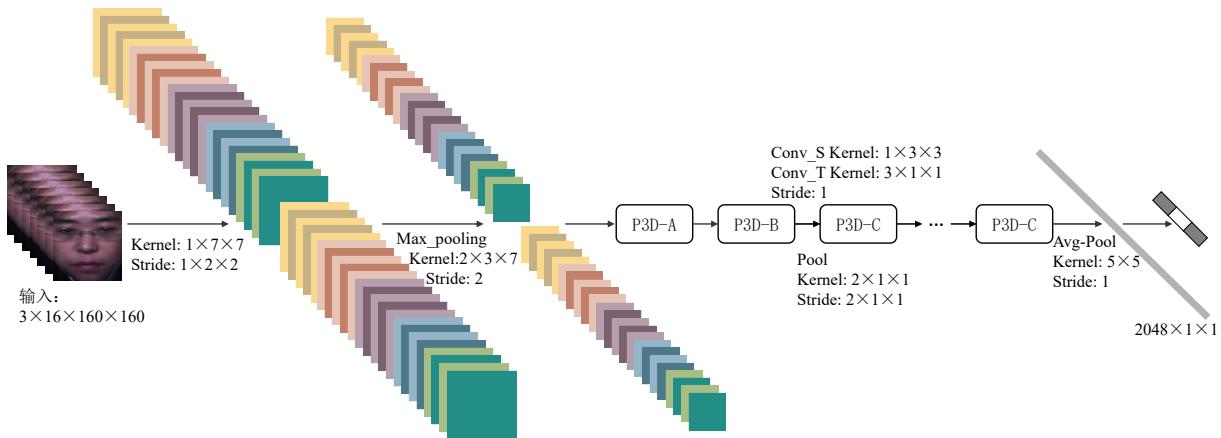


图 21 基于深度学习方法的低分辨率环境下微表情识别网络框架

4.1 数据集预处理

提取深度特征需要庞大的数据量支持，然而因为微表情的特殊性导致目前发表的数据集很少，所以对现有数据进行增强处理很有必要。数据增强（Data Augmentation）一般是指对图片进行随机的旋转、翻转、裁剪、随机设置图片的亮度和对比度以及对数据进行标准化（数据的均值为 0，方差为 1）。通过对数据增强的操作，可以让我们原本匮乏的数据变得稍微丰富。将原来的一张图片变为多张图片，这样扩大了样本容量，对于提高模型的准确率和提升模型的泛化能力非常有帮助。在本文中根据微表情数据的特殊性选择了其中的直方图均衡化、图像亮度变化和水平翻转三种方式，同时将现有的 SMIC-HS 和 CASME II 两个数据集做了融合，使得最终达到 4233 个片段，让模型的泛化能力进一步得到提升。

4.1.1 数据集融合

将 SMIC-HS 和 CASME II 两个数据集交叉融合，相似类归为一类。由原来的 16 个 subject（SMIC-HS 数据集）和 26 个 subject（CASME II 数据集）组合为现在的 42 个 subject，如表 8 所示。

表 8 融合后数据集情况

表情类	片段数	数据来源	
POSITIVE	83	51 (SMIC-HS, Positive)	32 (CASME II, Happy)
NEGATIVE	134	70 (SMIC-HS, Positive)	64 (CASME II, Disgust)
SURPRISE	68	43 (SMIC-HS, Surprise)	25 (CASME II, Surprise)
OTHERS	126	99 (CASME II, Others)	27 (CASME II, Repression)

论文 [21] 将第一版的 SMIC 数据集由原来的五类标签合并为最终的三类, 文中提到将第一版本的快乐分类 (Happy) 改为新的积极分类 (Positive), 新的消极分类 (Negative) 则是由第一版的悲伤 (Sadness)、恐惧 (Fear) 和厌恶 (Disgust) 三个分类组合而成。按照上述这种合并方式我们将 CASME II 中的快乐分类与 SMIC-HS 中的积极分类合并组成新的积极分类, 将 CASME II 中的厌恶分类与 SMIC-HS 中的消极分类合并组成新的消极分类, 将两种数据集的惊讶分类合并组成新的惊讶分类, 将 CASME II 的压抑分类和其他分类合并组成新的其他分类。

4.1.2 数据增强

直方图均衡化

直方图均衡化 (Histogram Equalization) 又称直方图平坦化, 实质上是对图像进行非线性拉伸, 重新分配图像象元值, 使一定灰度范围内象元值的数量大致相等。这样, 原来直方图中间的峰顶部分对比度得到增强, 而两侧的谷底部分对比度降低, 输出图像的直方图是一个较平的分段直方图: 如果输出数据分段值较小的话, 会产生粗略分类的视觉效果。

直方图是表示数字图像中每一灰度出现频率的统计关系。直方图能给出图像灰度范围、每个灰度的频度和灰度的分布、整幅图像的平均明暗和对比度等概貌性描述。灰度直方图是灰度级的函数, 反映的是图像中具有该灰度级像素的个数, 其横坐标是灰度级 r , 纵坐标是该灰度级出现的频率 (即像素的个数) $p_r(r)$, 整个坐标系描述的是图像灰度级的分布情况, 由此可以看出图像的灰度分布特性, 即若大部分像素集中在低灰度区域, 图像呈现暗的特性; 若像素集中在高灰度区域, 图像呈现亮的特性。

图 21 所示就是直方图均衡化, 即将随机分布的图像直方图修改成均匀分布的直方图。基本思想是对原始图像的像素灰度做某种映射变换, 使变换后图像灰度的概率密度呈均匀分布。这就意味着图像灰度的动态范围得到了增加, 提高了图像的对比度。

通过这种技术可以清晰地在直方图上看到图像亮度的分布情况, 并可按照需要对图像亮度调整。另外, 这种方法是可逆的, 如果已知均衡化函数, 就可以恢复原始直方图。

设变量 r 代表图像中像素灰度级。对灰度级进行归一化处理, 则 $0 \leq r \leq 1$, 其中 $r = 0$ 表示黑, $r = 1$ 表示白。对于一幅给定的图像来说, 每个像素值在 $[0, 1]$ 的灰度级是随机的。用概率密度函数 $p_r(r)$ 来表示图像灰度级的分布。

为了有利于数字图像处理, 引入离散形式。在离散形式下, 用 r_k 代表离散灰度级, 用 $p_r(r_k)$ 代表 $p_r(r)$, 并且下式成立: $p_r(r_k) = n_k/n$, 其中, $0 \leq r_k \leq 1$, $k = 0, 1, 2, \dots, L - 1$ 。式中 n_k 为图像中出现 r_k 这种灰度的像素数, n 是图像中的像素总数, 而 n_k/n 就是概率

论中的频数。图像进行直方图均衡化的函数表达式为:

$$S_i = T(r_i) = \sum_{i=0}^{k-1} \frac{n_i}{n} \quad (4.1)$$

式中, k 为灰度级数。相应的反变换为:

$$r_i = T^{-1}(S_i) \quad (4.2)$$

4.2 特征提取及识别

P3D 效果比 C3D 好太多

其他还有 I3D、ResNet 和 P3D

T3D 效果好点, 但提升不大, 且不好训练

I3D 则要结合传统特征

4.2.1 伪 3D 块

受最近残差网络 (ResNet) 在众多具有挑战性的图像识别任务中取得成功的启发, 我们开发了一个名为伪 3D (P3D) 块的构建模块族, 以取代 ResNet 中的 2D 残差单元, 在视频的 ResNet-like 架构中实现时空编码。接下来, 我们将回顾 ResNet 中剩余单元的基本设计, 然后介绍如何设计 P3D 块。最后阐述了每个 P3D 块上的瓶颈构建体系结构。

残差单位

ResNet 由许多残余单元组成, 每个残余单元通常由:

$$\mathbf{x}_{t+1} = \mathbf{h}(\mathbf{x}_t) + \mathbf{F}(\mathbf{x}_t) \quad (4.3)$$

组成, 其中 \mathbf{x}_t 和 \mathbf{x}_{t+1} 表示第 t 个残差单元的输入和输出, $\mathbf{h}(\mathbf{x}_t) = \mathbf{x}_t$ 为恒等映射, \mathbf{F} 为非线性残差函数。如图 9 所示。因此, 式 4.3 可以改写为:

$$(\mathbf{I} + \mathbf{F}) \cdot \mathbf{x}_t = \mathbf{x}_t + \mathbf{F} \cdot \mathbf{x}_t := \mathbf{x}_t + \mathbf{F}(\mathbf{x}_t) = \mathbf{x}_{t+1} \quad (4.4)$$

其中 $\mathbf{F} \cdot \mathbf{x}_t$ 表示在 \mathbf{x}_t 上执行残差函数 \mathbf{F} 的结果。ResNet 的主要思想是通过一个快捷的连接来学习参考单元输入 \mathbf{x}_t 的可加性残差函数 \mathbf{F} , 而不是直接学习未引用的非线性函数。

P3D 块设计

为了将 ResNet 中的每个 2D 残差单元更改成用于编码时空视频信息的 3D 结构, 我

们按照 3.1 节中介绍的伪 3D 原理对 ResNet 中的基本残差单元进行了修改，并设计了几个伪 3D 块。由于涉及两个设计问题，所以修改并不简单。第一个问题是空间维度 (\mathbf{S}) 上的二维滤波器模块和时间域 (\mathbf{T}) 上的一维滤波器模块是否应该直接或间接地相互影响。两种滤波器之间的直接影响是将空间二维滤波器的输出作为时间一维滤波器的输入（即，以级联的方式连接）。两个滤波器之间的间接影响使连接分离，使每一种滤波器在网络的不同路径上（即，以并联的方式连接）。第二个问题是这两种滤波器是否都应该是直接影响最终的输出。因此，在此上下文中，直接影响表示每种滤波器的输出都应该直接连接到最终输出。

基于这两个设计问题，我们推导出如图 2 所示的三个不同的 P3D 块，分别命名为 P3D-A、P3D-B 和 P3D-C。关于它们的架构的详细比较如下：

(1) P3D-A：第一种设计考虑层加结构，使时间一维滤波器 (\mathbf{T}) 以级联方式跟随空间二维滤波器 (\mathbf{S})。因此，两种滤波器在同一路径上可以直接相互影响，时间一维滤波器直接连接到最终输出：

$$(\mathbf{I} + \mathbf{T} \cdot \mathbf{S}) \cdot \mathbf{x}_t := \mathbf{x}_t + \mathbf{T}(\mathbf{S}(\mathbf{x}_t)) = \mathbf{x}_{t+1} \quad (4.5)$$

(2) P3D-B：第二种设计与第一种设计相似，考虑了两种滤波器之间的间接影响，两种滤波器以并行的方式分布在不同的路径上。虽然 \mathbf{S} 和 \mathbf{T} 之间没有直接的影响，但是它们都直接累加到最终的输出中，可以表示为：

$$(\mathbf{I} + \mathbf{S} + \mathbf{T}) \cdot \mathbf{x}_t := \mathbf{x}_t + \mathbf{S}(\mathbf{x}_t) + \mathbf{T}(\mathbf{x}_t) = \mathbf{x}_{t+1} \quad (4.6)$$

(3) P3D-C：最后一个设计是在 P3D-A 和 P3D-B 之间寻求折中，即同时建立了 \mathbf{S} 、 \mathbf{T} 和最终输出之间的直接影响。具体来说，为了基于级联 P3D-A 结构实现 \mathbf{S} 与最终输出的直接连接，我们建立了 \mathbf{S} 到最终输出的连接，使输出 \mathbf{x}_{t+1} 为：

$$(\mathbf{I} + \mathbf{S} + \mathbf{T} \cdot \mathbf{S}) \cdot \mathbf{x}_t := \mathbf{x}_t + \mathbf{S}(\mathbf{x}_t) + \mathbf{T}(\mathbf{S}(\mathbf{x}_t)) = \mathbf{x}_{t+1} \quad (4.7)$$

瓶颈 (Bottleneck) 结构

在确定二维残差单元的结构时，对二维基本块进行瓶颈设计，以降低计算复杂度。特别的，如图 3 所示 (a)，残差单位采用 1×1 、 3×3 和 1×1 三层叠加的卷积网络，而不是一个单一的二维滤波器 (3×3 卷积)，其中第一个和最后一个 1×1 卷积层的作用分别是减少和恢复输入样本的维度。这种瓶颈设计使得中间的 3×3 卷积层成为瓶颈，这种

瓶颈结构具有更小的输入和输出维度。因此，我们按照这种完美的结构实现提出的 P3D 设计：由一个空间二维滤波器（ $1 \times 3 \times 3$ 卷积）和一个时间一维滤波器（ $3 \times 1 \times 1$ 卷积）组合成主要部分，同时将两个 $1 \times 1 \times 1$ 卷积添加在路径的两端，负责对维度的降低和恢复。从而，该瓶颈结构减少了空间二维滤波器和时间一维滤波器的输入、输出维度。图 3 (b) -3 (d) 展示了这三个 P3D 块上详细的瓶颈构建体系结构。

4.2.2 P3D ResNet

为了验证三个 P3D 模块的优点，我们首先开发了三个 P3D ResNet 变体，即，P3D-A ResNet、P3D-B ResNet 和 P3D-C ResNet，分别用一种 P3D 块替换 50 层 ResNet（ResNet-50）中的所有残余单元。比较了基本 ResNet-50 和三种 P3D ResNet 变体的性能和时间效率。然后，从结构多样性的角度，将三个 P3D 块混合在一起，提出了一个完整的 P3D ResNet 版本。

混合不同的 P3D 块。最近在深度网络设计中追求结构多样性的成功案例进一步激发了我们的设计灵感，促使我们设计了一个完整的 P3D ResNet 版本，通过在结构中混合不同的 P3D 块来增强结构多样性，如图 4 所示。特别地，我们按照 P3D-A、P3D-B 和 P3D-C 这样顺序的 P3D 链替换剩余的单元。表 1 详细说明了完整 P3D ResNet 的性能和速度。通过进一步追求结构多样性，P3D ResNet 相对于 P3D-A ResNet、P3D-B ResNet 和 P3D-C ResNet 的准确率分别提高了 0.5%、1.4% 和 1.2%，说明随着深度的增加，结构多样性的增强可以提高神经网络的能力。

在视频分类或理解领域，容易从图像领域的 2D 卷积联想到用 3D 卷积来做，虽然用 3D 卷积进行特征提取可以同时考虑到空间和时间维度的特征，但是计算成本和模型存储都太大，因此这篇文章针对视频领域中采用的 3D 卷积进行改造，提出 Pseudo-3D Residual Net（P3D ResNet），思想有点像当年的 Inception v3 中用 1×3 和 3×1 的卷积叠加代替原来的 3×3 卷积，这篇文章是用 $1 \times 3 \times 3$ 卷积和 $3 \times 1 \times 1$ 卷积代替 $3 \times 3 \times 3$ 卷积（前者用来获取空间维度的特征，实际上和 2D 的卷积没什么差别；后者用来获取时间维度的特征，因为倒数第三维是帧的数量），毕竟这样做可以大大减少计算量，而如果采用 3D 卷积来做的话，速度和存储正是瓶颈，这也使得像 C3D 算法的网络深度只有 11 层，参看图 1。该文章的网络结构可以直接在 3D 的 ResNet 网络上修改得到。顺便提一下，除了采用 3D 卷积来提取时间维度上的特征外，还可以采用 LSTM 来提取，这也是当前视频研究的一个方向。

图 1 是几个模型在层数、模型大小和在 Sports-1M 数据集上的视频分类效果对比，其中的 P3D ResNet 是在 ResNet 152 基础上修改得到的，深度之所以不是 152，是因为改造后的每个残差结构不是原来 ResNet 系列的 3 个卷积层，而是 3 或 4 个卷积层，详细可

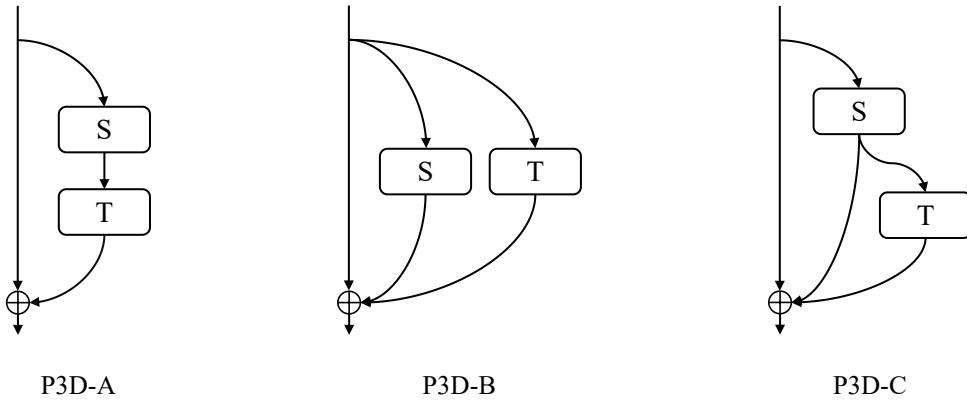


图 22 三种 P3D 块设计

以看图 3, 所以最后网络深度是 199 层。官方 GitHub 代码中的网络就是 199 层的。ResNet 152 是直接在 Sports-1M 数据集上 Fine-Tune 得到的。可以看出 199 层的 P3D ResNet 虽然在模型大小上比 ResNet-152 (此处 ResNet-152 是在 sports-1M 数据集上 fine tune 得到的) 大一些, 但是准确率提升比较明显, 与 C3D (此处 C3D 是直接在 sports-1M 数据集上从头开始训练得到的) 的对比在效果和模型大小上都有较大改进, 除此之外, 速度的提升也是亮点, 后面有详细的速度对比。

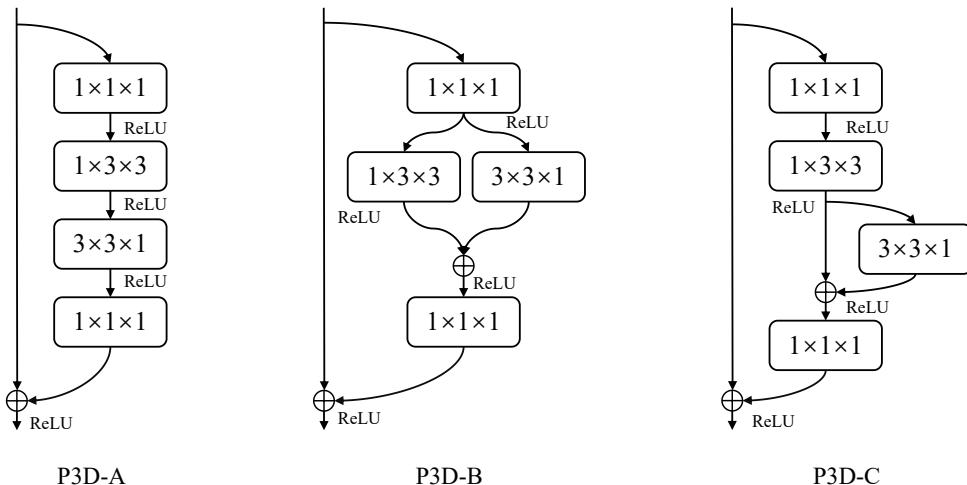


图 23 三种 P3D 瓶颈块结构设计

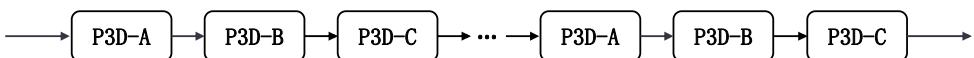


图 24 P3D-A、P3D-B、P3D-C 级联的 P3D 残差网络

4.3 实验设置及分析

4.3.1 数据增强

4.3.2 特征提取及识别

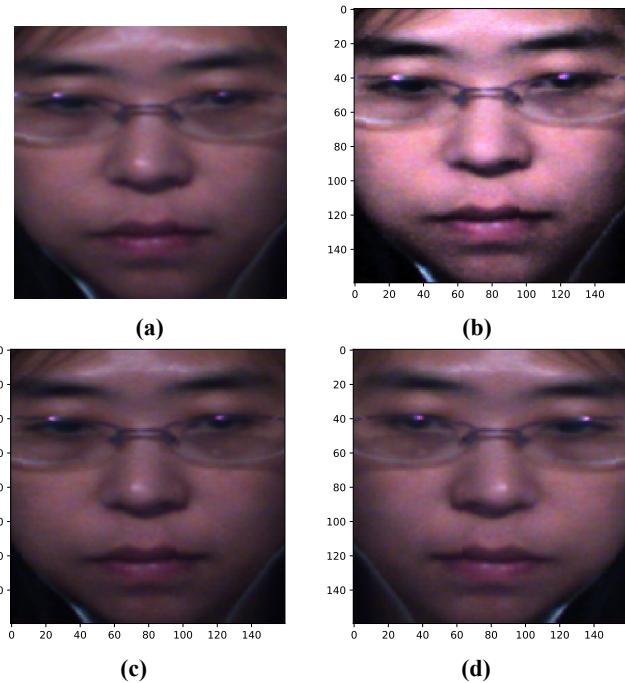


图 25 直方图均衡化样例

(a) 原图, (b) 直方图均衡化结果, (c) 图像亮度变化结果, (d) 水平翻转结果

4.4 本章小结

第五章 低分辨率环境下微表情识别系统

为了将本文算法演示出来以提供更为直观的视觉效果，本章利用 MATLAB GUI 设计实现了一款低分辨率环境下微表情识别的展示系统。通过向该系统上传视频（或图像序列）选择合适的参数设置，输出显示对应的识别结果。

5.1 需求分析

低分辨率环境下微表情识别展示系统的主要目的是为了让研究人员能更直观的了解微表情的识别结果和对微表情数据集的理解，同时在本文中为了让文章算法更直观的呈现。介于上述目的本章将重点突出在系统可视化设计部分，将数据的输入和结果的输出作为重点，以尽量简洁的方式表达。

5.2 系统设计

一款可发布的应用程序或者算法为使使用者能够更加方便、快速地理解和使用都需要设计一个方便操作的系统，且配备相对简易的操作界面。为使本文方法更便于用户理解和学习，在本章利用 MATLAB GUI 设计了一款低分辨率环境下微表情识别的展示系统。

5.2.1 功能设计

通过对章节5.1的分析发现该展示系统的重点为输入输出功能，如图26 所示通过对需求的梳理设计了数据输入、参数设置、结果可视化和数据输出四个模块。其中在数据设置模块主要针对分类器 SVM 参数的设置和对分辨率的设置。前者可以通过不同参数的设置应用不同的分类器以适合不同的数据，同时也可反映在不同参数设置下的实验对照效果。后者的分辨率设置主要针对低分辨率视频是否采用重建后图像序列设置，同样，该功能的设计考虑的是不同实验组间的对比。

在结果可视化部分尽可能多的对结果展示，包括超分辨重建效果的展示和微表情识别效果的展示。主要是通过相关指标完成，如针对超分辨重建的 PSNR 指标和 SSIM 指标，上述两个指标的结合很够有力的反应重建效果；微表情识别的指标主要为准确度的呈现和最终可能的表情类，此处将各类表情的准确度均可视化，目的是增加数据的可信度。

最后一个模块是数据输出模块，作为结果可视化的一部分该部分主要是输出一份以数据为主题的识别报告。

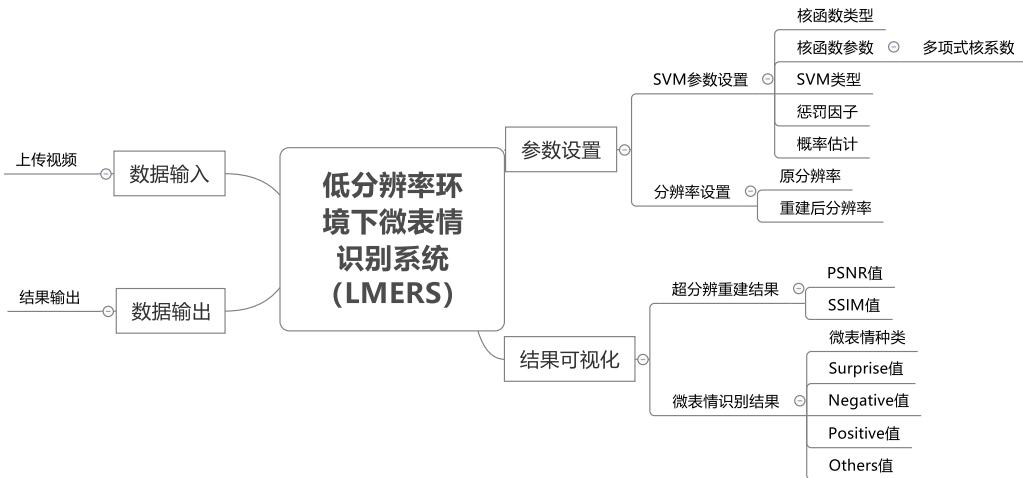


图 26 微表情识别系统功能结构图

5.2.2 界面设计

MATLAB GUI 是一种新型的图形用户界面开发环境，在 GUI 中用户既能嵌入已经存在实现的仿真程序，还能够以动态方式将所仿真的图像化结果表现出来，具有良好的人机交互性和实际应用性。

在 MATLAB 中可以通过以下两种方式来设计系统界面：

(1) 通过编写程序来设计。在 MATLAB 中用户能够通过编写.m 文件来实现系统所需要的任意界面并实现相应的功能。

(2) 使用可视化的界面环境。相对直接编写.m 文件来讲，GUI 还为用户提供了另一种相对方便高效的方法，即 `guide` 方法。用户只需在 MATLAB 的命令框中输入 `guide` 命令，则系统会立即自动生成两个文件，后缀名分别为.fig 和.m，其中.fig 是资源文件，而.m 文件则包含界面初始化的相关代码，通过 `guide` 方法，用户能够将所需要的组件直接放到界面区域并调整相应布局。本章采用第二种方式来制作演示系统。

本章设计的演示系统主要包括主界面和修复界面。主界面如图 5-1 所示，包括 4 个部分：点击“立即体验”直接跳转到修复界面，如图 5-2 所示；点击“系统说明”可以查看该系统的主要功能相关介绍，如图 5-3 所示；点击“关于”可以查看该系统设计的相关信息，如图 5-4 所示；点击“退出”会出现图 5-5 的提示窗，点击“Yes”退出演示系统，点击“No”或“Cancel”则关闭提示窗并回到主界面。

修复界面下总共包括“读取图像”、“图像修复算法”、“保存修复结果”和“退出”四个模块，各个模块的功能将在下文中介绍。

5.2.3 操作样例



图 27 低分辨率环境下微表情识别系统

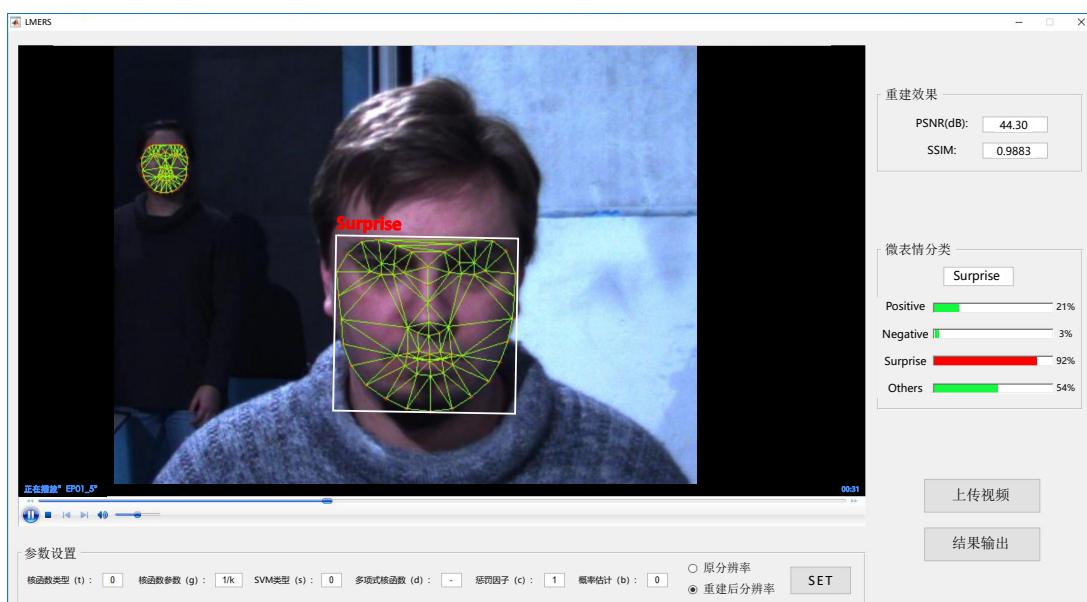


图 28 低分辨率环境下微表情识别样例

5.3 本章小结

为了使本文算法演示起来更加方便简单，设计了一款低分辨率环境下微表情识别效果展示系统，在这款系统中用户可以通过上传视频，并通过设置不同的参数对不同的视频片段分析并输出显示对应的识别结果。

第六章 总结与展望

6.1 总结

在未来的工作中，可以从四个方面继续和完善微表情的研究。首先，关于微表情数据库：为了开发更复杂的计算模型，仍然需要更多自发的微表情数据。与普通人脸表情数据库相比，目前微表情数据库的规模还不够大。未来微表情数据的收集可以通过三种方式进行改进：一是增加样本量；二是增加 AU 标签；第三个是包含深度信息来构建 3D 微表情模型。目前已知有一组英国研究人员正在合作建立一个大型 3D 微表情数据库。

第二，关于微表情检测：2.5 节中描述的通过特征差检测微表情的分析框架是第一个从自发长视频中提取微表情的方法。当前微表情检测框架面临的一个挑战是，需要排除微表情中其他短暂但非情绪的动作（例如眨眼）。未来将在 AU 水平上开发更精细的检测方法，排除非情绪短暂运动，降低假阳性率。此外，未来的微表情检测方法也将致力于提供更精确的微表情产生的时间信息，包括起始帧、峰值帧和终止帧。

第三，关于微表情识别：第三篇论文中提出的最新方法比之前的方法有优势，增加了放大细微运动步骤。如果其他视频处理方法被证明对微表情识别任务有帮助，我们将探索并添加到该框架中。将研究更复杂的机器学习模型，包括深度学习模型。也计划在新的 3D 微表情数据库完成后使用 3D 信息进行微表情识别。

第四，微表情检测与识别集成系统：在微表情检测与识别方法取得进展后，计划构建先进的微表情检测与识别集成系统，提高微表情检测与识别的准确率。

论文的贡献来自两个主要方面，每个方面都对应于我的研究的一个目标。贡献的第一个方面是关于自动微表情分析。微表情可以帮助揭示人们隐藏的感受，因此可以作为谎言检测的重要线索。几十年来，心理学家一直在研究微表情的现象，但直到 2009 年才开始进行计算机视觉领域的研究。进行微表情分析研究的第一个障碍是缺乏自发的微表情数据。之前的一些研究使用了摆拍的微表情片段，但是摆拍的微表情是非自愿行为与自发的微表情存在很大差异。2011 年，我们提出在论文 I 中使用抑制情绪诱导方式来构建第一个自发微表情数据集 SMIC。我们还提出了第一个框架，使用 TIM 插值和 LBP-TOP 作为自发微表情识别的特征描述符。第一版的 SMIC 数据集只有有限的样本，后来扩展的 SMIC 完整版本，包括从 16 名参与者中获得的 164 个自发的微表情。SMIC 数据库在线共享用于研究用途。第二篇详细解释了诱导和标注 SMIC 的方法，以便为将来的微表情数据收集提供有用的信息。SMIC 数据库吸引了其他研究人员的兴趣。从那时起，更多的微表情数据库开始出现，并且更多的方法被用于微表情分析。在我们最近

的论文三的工作中，微表情检测和微表情识别问题都得到了解决。提出了一种基于特征差的微表情检测方法，该方法被证明对于从长视频中发现自发微表情是有效的。还提出了一种先进的微表情识别框架，该框架采用运动放大过程来消除微表情的微弱性。为了使微表情识别过程合理化以获得更好的性能，对框架的许多重要因素（例如，特征类型、特征维度和插值帧数）进行了彻底的探索。结果表明，所提出的微表情识别框架在 SMIC 和 CASMEII 数据库上都优于其他最先进的方法。

6.2 存在的问题与展望

6.2.1 存在的问题

关于微表情的研究目前还处于起步阶段，未来具有良好的发展前景。目前的微表情研究可以在未来的工作中从四个方面继续和改进。

首先，关于微表情数据库：为了开发更复杂的计算模型，仍然需要更多自发的微表情数据。与普通的人脸数据库相比，当前微表情数据库的规模还不够大。未来的微表情数据收集可以通过三种方式进行改进：第一种是增加样本量；第二种是增加 AU 标签；第三是包含深度信息以构建 3D 微表情模型。目前正在与一群英国研究人员合作建立一个大型 3D 微表情数据库。第二，关于微表情检测：第 2.5 节中描述的使用微表情点测量特征差异分析的框架是第一种从自发长视频中发现微表情的方法。当前定位框架的一个挑战是需要从微表情中排除其他短暂但非情绪化的运动（例如，眨眼）。在未来，将在 AU 级别上开发更精细的定位方法，从而可以排除非情绪的短暂动作以降低误报率。此外，未来的微表情点测方法还将尝试以提供微表情的更精确的时间信息为目标，包括起始帧，顶点和偏移帧。第三，关于微表情识别：纸张 III 中提出的最新方法通过采用一个额外步骤来放大微妙运动，显示出优于先前方法的优势。如果它们被证明对微表情识别任务有帮助，则将探索其他视频处理方法并将其添加到框架中。将研究更复杂的机器学习模型，包括深度学习模型。当新的 3D 微表情数据库完成时，还计划使用 3D 信息进行微表情识别。第四，关于集成的微表情点样和识别系统：在微表情识别方法和微表情点样方法的进展之后，还计划构建先进的集成系统以实现更准确的微表情点样和识别。

6.2.2 展望

除了继续研究这两个主题之外，另一个有价值的研究方向是将它们结合起来构建一个多模式系统，用于仅使用视频作为输入的情感状态分析。文献综述结果表明，有可能从面部视频中提取其他生理信息，如呼吸率和血压。因此，计划是将微表情与所有可从面部实现的生理信号结合起来进行情绪状态分析。这个想法可能特别适合检测覆盖的情绪变化，而脸上没有明显的表情。

参考文献

- [1] Haggard E A, Isaacs K S. Micromomentary facial expressions as indicators of ego mechanisms in psychotherapy[M/OL]. Springer US, 1966: 154-165. https://doi.org/10.1007/978-1-4684-6045-2_14.
- [2] Ekman P, Friesen W V. Nonverbal leakage and clues to deception[J]. Psychiatry, 1969, 32(1):88-106.
- [3] Mehrabian A, Ferris S R. Inference of attitudes from nonverbal communication in two channels[J]. Journal of Consulting Psychology, 1967, 31(3):248.
- [4] Kazlev M. The triune brain[J/OL]. KHEPER, 1999, 5(19)[2003-11-19]. <http://www.kheper.net/topics/intelligence/MacLean.htm>.
- [5] Chiu M H, Chou C C, Wu W L, et al. The role of facial microexpression state (fmes) change in the process of conceptual conflict[J]. British Journal of Educational Technology, 2014, 45(3):471-486.
- [6] Yan W J, Wu Q, Liang J, et al. How fast are the leaked facial expressions: The duration of micro-expressions[J]. Journal of Nonverbal Behavior, 2013, 37(4):217-230.
- [7] Matsumoto D, Hwang H S. Evidence for training the ability to read microexpressions of emotion[J]. Motivation and Emotion, 2011, 35(2):181-191.
- [8] Porter S, Brinke L T. Reading between the lies: Identifying concealed and falsified emotions in universal facial expressions[J]. Psychological Science, 2008, 19(5):508-514.
- [9] 周凯莉. 别对我撒谎, 我懂“微表情” [N/OL]. 中国青年报, 2010, 11(10). http://zqb.cyol.com/content/2010-11/10/content_3441411.htm.
- [10] Ekman, Paul, Sullivan O, et al. A few can catch a liar[J]. Psychological Science, 1999, 10(3):263-266.
- [11] Ekman P, Friesen W. Facial action coding scheme (facs): A technique for the measurement of facial action[M]. Palo Alto, CA: Consulting Psychologists Press. Google Scholar, 1978.
- [12] Maja P. Machine analysis of facial behaviour: naturalistic and dynamic behaviour[J]. Philosophical Transactions of the Royal Society of London, 2009, 364(1535):3505-3513.
- [13] Li X, Hong X, Moilanen A, et al. Towards reading hidden emotions: A comparative study of spontaneous micro-expression spotting and recognition methods[J]. IEEE Transactions on Affective Computing, 2017, PP(99):1-1.
- [14] Li X. Reading subtle information from human faces[D/OL]. Doctoral Dissertation: Acta Universitatis Ouluensis. C, Technica, 2017[2017-09-08]. <http://urn.fi/urn:isbn:9789526216386>.
- [15] Ekman P, Friesen W V. Detecting deception from the body or face[J]. Journal of Personality & Social Psychology, 1974, 29(3):288-298.
- [16] 殷明, 张剑心, 史爱芹, 等. 微表情的特征、识别、训练和影响因素[J]. 心理科学进展, 2016, 24(11): 1723-1736.
- [17] Matsumoto D, Leroux J, Wilsoncohn C, et al. A new test to measure emotion recognition ability: Matsumoto and ekman's japanese and caucasian brief affect recognition test (jacbart)[J]. Journal of Nonverbal Behavior, 2000, 24(3):179-209.

- [18] Ekman P. Mett. micro expression training tool[J]. CD-ROM. Oakland, 2003.
- [19] Yan W J, Wu Q, Liu Y J, et al. Casme database: a dataset of spontaneous micro-expressions collected from neutralized faces[C]//IEEE International Conference & Workshops on Automatic Face & Gesture Recognition. 2013.
- [20] Yan W J, Li X, Wang S J, et al. Casme ii: an improved spontaneous micro-expression database and the baseline evaluation[J]. Plos One, 2014, 9(1):e86041.
- [21] Li X, Pfister T, Huang X, et al. A spontaneous micro-expression database: Inducement, collection and baseline[C]//IEEE International Conference & Workshops on Automatic Face & Gesture Recognition. 2013.
- [22] Davison A K, Lansley C, Costen N, et al. Samm: A spontaneous micro-facial movement dataset[J]. IEEE Transactions on Affective Computing, 2018, 9(1):116-129.
- [23] Zeng Z, Fu Y, Roisman G I, et al. Spontaneous emotional facial expression detection.[J]. Journal of multimedia, 2006, 1(5):1-8.
- [24] Królak A, Strumiłło P. Eye-blink detection system for human – computer interaction[J]. Universal Access in the Information Society, 2012, 11(4):409-419.
- [25] Liwicki S, Zafeiriou S, Pantic M. Incremental slow feature analysis with indefinite kernel for online temporal video segmentation[M]. 2012.
- [26] Shreve M, Godavarthy S, Manohar V, et al. Towards macro-and micro-expression spotting in video using strain patterns.[C]//Applications of Computer Vision. Citeseer, 2009: 1-6.
- [27] Shreve M, Godavarthy S, Goldgof D, et al. Macro- and micro-expression spotting in long videos using spatio-temporal strain[J]. 2011.
- [28] Polikovsky S, Kameda Y, Ohta Y. Facial micro-expressions recognition using high speed camera and 3d-gradient descriptor[C]//International Conference on Crime Detection & Prevention. 2009.
- [29] Polikovsky S, Kameda Y, Ohta Y. Facial micro-expression detection in hi-speed video based on facial action coding system (facs)[J]. Ieice Transactions on Information & Systems, 2013, 96(1):81-92.
- [30] Qi W, Shen X, Fu X. The machine knows what you are hiding: An automatic micro-expression recognition system[C]//International Conference on Affective Computing & Intelligent Interaction. 2011.
- [31] Warren G, Schertler E, Bull P. Detecting deception from emotional and unemotional cues[J]. Journal of Nonverbal Behavior, 2009, 33(1):59-69.
- [32] Pfister T, Li X, Zhao G, et al. Recognising spontaneous facial micro-expressions[C]//Computer Vision (ICCV), 2011 IEEE International Conference on. IEEE, 2011.
- [33] Ruiz-Hernandez J A, Pietikäinen M. Encoding local binary patterns using the re-parametrization of the second order gaussian jet[C]//Automatic Face and Gesture Recognition (FG), 2013 10th IEEE International Conference and Workshops on. IEEE, 2013.
- [34] Davison A K, Yap M H, Costen N, et al. Micro-facial movements: An investigation on spatio-temporal descriptors[C]//European Conference on Computer Vision. 2014.
- [35] Yao S, Ning H, Zhang H, et al. Micro-expression recognition by feature points tracking[C]//International Conference on Communications. 2014.

- [36] Xia Z, Feng X, Peng J, et al. Spontaneous micro-expression spotting via geometric deformation modeling[J]. Computer Vision & Image Understanding, 2016, 147(C):87-94.
- [37] Huang X, Wang S J, Zhao G, et al. Facial micro-expression recognition using spatiotemporal local binary pattern with integral projection[C]//Workshop on Computer Vision for Affective Computing at Iccv. 2015.
- [38] Wang S J, Yan W J, Li X, et al. Micro-expression recognition using dynamic textures on tensor independent color space[C]//2014 22nd International Conference on Pattern Recognition (ICPR). IEEE, 2014.
- [39] Wang S J, Yan W J, Zhao G, et al. Micro-expression recognition using robust principal component analysis and local spatiotemporal directional features[C]//Workshop at the European conference on computer vision. Springer, 2014.
- [40] Wang Y, See J, Phan R C W, et al. Lbp with six intersection points: Reducing redundant information in lbp-top for micro-expression recognition[C]//Asian Conference on Computer Vision. Springer, 2014.
- [41] Xiaohua H, Wang S J, Liu X, et al. Discriminative spatiotemporal local binary pattern with revisited integral projection for spontaneous facial micro-expression recognition[C]//IEEE Transactions on Affective Computing. IEEE, 2017.
- [42] Wang Y, See J, Phan R C W, et al. Efficient spatio-temporal local binary patterns for spontaneous facial micro-expression recognition[C]//PloS one. Public Library of Science, 2015.
- [43] Hong X, Xu Y, Zhao G. Lbp-top: a tensor unfolding revisit[J]. 2016.
- [44] Liu Y J, Zhang J K, Yan W J, et al. A main directional mean optical flow feature for spontaneous micro-expression recognition[C]//IEEE Transactions on Affective Computing. IEEE, 2016.
- [45] Liong S T, See J, Phan R C W, et al. Subtle expression recognition using optical strain weighted features [C]//Asian Conference on Computer Vision. Springer, 2014: 644-657.
- [46] Xu F, Zhang J, Wang J Z. Microexpression identification and categorization using a facial dynamics map[C]//IEEE Transactions on Affective Computing. IEEE, 2017.
- [47] Song Y, Morency L P, Davis R. Learning a sparse codebook of facial and body microexpressions for emotion recognition[J]. 2013.
- [48] Le Ngo A C, Phan R C W, See J. Spontaneous subtle expression recognition: Imbalanced databases and solutions[C]//Asian conference on computer vision. Springer, 2014.
- [49] Lu Z, Luo Z, Zheng H, et al. A delaunay-based temporal coding model for micro-expression recognition [C]//Asian conference on computer vision. Springer, 2014.
- [50] Oh Y H, Le Ngo A C, See J, et al. Monogenic riesz wavelet representation for micro-expression recognition[C]//Digital Signal Processing (DSP), 2015 IEEE International Conference on. IEEE, 2015.
- [51] He J, Hu J F, Lu X, et al. Multi-task mid-level feature learning for micro-expression recognition[C]// Pattern Recognition. Elsevier, 2017.
- [52] Patel D, Hong X, Zhao G. Selective deep features for micro-expression recognition[C]//International Conference on Pattern Recognition. 2016.

- [53] Li Y, Huang X, Zhao G. Can micro-expression be recognized based on single apex frame?[C/OL]// 2018 25th IEEE International Conference on Image Processing (ICIP). 2018: 3094-3098. DOI: 10.1109/ICIP.2018.8451376.
- [54] Lyons M J, Akamatsu S, Kamachi M, et al. Coding facial expressions with gabor wavelets[C]//IEEE International Conference on Automatic Face & Gesture Recognition. 2002.
- [55] Belhumeur P N, Hespanha J P, Kriegman D J. Eigenfaces vs. fisherfaces: recognition using class specific linear projection[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2002, 19(7):711-720.
- [56] Lucey P, Cohn J F, Kanade T, et al. The extended cohn-kanade dataset (ck+): A complete dataset for action unit and emotion-specified expression[C]//Computer Vision & Pattern Recognition Workshops. 2010.
- [57] Coan J A, Allen J J B. Handbook of emotion elicitation and assessment[J]. Neuroimage, 2015, 37(3): 866-875.
- [58] Ojala T, Pietikäinen M, Mäenpää T. Gray scale and rotation invariant texture classification with local binary patterns[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2002, 24(7):971-987.
- [59] Zhao G, Pietikäinen M. Dynamic texture recognition using local binary patterns with an application to facial expressions[C]//IEEE transactions on pattern analysis and machine intelligence. IEEE, 2007.
- [60] Gibson J J. The perception of the visual world[M]. Boston: Houghton Mifflin, 1950.
- [61] Poggio T, Reichardt W. Visual control of orientation behaviour in the fly: Part ii. towards the underlying neural interactions[J]. Quarterly reviews of biophysics, 1976, 9(3):377-438.
- [62] Lucas B D, Kanade T. An iterative image registration technique with an application to stereo vision [C]//Proceedings of the 7th International Joint Conference on Artificial Intelligence. 1981: 674-679.
- [63] Horn B K, Schunck B G. Determining optical flow[J/OL]. Artificial Intelligence, 1981, 17(1):185-203. <http://www.sciencedirect.com/science/article/pii/0004370281900242>.
- [64] Barron J L, Fleet D J, Beauchemin S S. Performance of optical flow techniques[C]//Computer Vision and Pattern Recognition, 1992 IEEE Computer Society Conference on. 1992: 43-77.
- [65] Daugman J G. Complete discrete 2-d gabor transforms by neural networks for image analysis and compression[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1988, 36(7):1169-1179.
- [66] Kyrki V, Kamarainen J K, Kälviäinen H. Simple gabor feature space for invariant object recognition [J]. Pattern Recognition Letters, 2004, 25(3):311-318.
- [67] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [68] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C]//Advances in neural information processing systems. 2012: 1097-1105.
- [69] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. Computer Science, 2014.

-
- [70] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
 - [71] Shuiwang J, Ming Y, Kai Y. 3d convolutional neural networks for human action recognition[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2013, 35(1):221-231.
 - [72] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
 - [73] Srivastava R K, Greff K, Schmidhuber J. Highway networks[J]. Computer Science, 2015.
 - [74] Lei Z, Ahonen T, Pietikäinen M, et al. Local frequency descriptor for low-resolution face recognition[C]//Automatic Face and Gesture Recognition and Workshops (FG 2011), 2011 IEEE International Conference on. IEEE, 2011.
 - [75] Wang Z, Miao Z, Wu Q J, et al. Low-resolution face recognition: a review[C]//The Visual Computer. Springer, 2014.
 - [76] Shi J, Liu X, Zong Y, et al. Hallucinating face image by regularization models in high-resolution feature space[C]//IEEE Transactions on Image Processing. IEEE, 2018.
 - [77] Cootes T F, Taylor C J, Cooper D H, et al. Active shape models-their training and application[C]//Computer vision and image understanding. Elsevier, 1995.
 - [78] Goshtasby A. Image registration by local approximation methods[C]//Image and Vision Computing. Elsevier, 1988.
 - [79] Zhou Z, Zhao G, Pietikäinen M. Towards a practical lipreading system[C]//Computer Vision and Pattern Recognition (CVPR), 2011 IEEE Conference on. IEEE, 2011.
 - [80] Chang C C, Lin C J. Libsvm: a library for support vector machines[C]//ACM transactions on intelligent systems and technology (TIST). ACM, 2011.

致谢

寒来暑往，秋收冬藏，校园里的白玉兰不知不觉已绽放了三季，而我也已在研究生的时光里荡漾了三个春秋。在这三年里从对学术的懵懂无知到渐入佳境，从膜拜大牛的论文到完成自己学术生涯里的第一篇论文，从一位只知道 PCB、单片机的硬件人到对人工智能稍有了解的程序猿。

攻读硕士学位期间取得的科研成果

1. 发表学术论文

Micro-expression Recognition Under Low-resolution Cases

2. 申请（授权）专利

《一种低分辨率环境微表情识别的方法》

